系统设计
Distributed System Design 2
（九章网站下载最新课件）

本节主讲人：北丐老师

今日课程大纲

- Design a Bigtable
  - NoSQL database 设计框架和原理
  - SStable 读和写
  - Bloom Filter

Interviewer: What is bigtable?

What is BigTable?

NoSQL DataBase	Company
Bigtable	Google
Hbase	Open Source of Bigtable
Cassandra	Facebook
DynamoDB	Amazon

Comparison of different No SQL database:
https://www.digitalocean.com/community/tutorials/a-comparison-of-nosql-database-management-systems-and-models

为什么我们要讲bigtable 的实现？

1. Google面试题
2. 解决相类似系统设计题,比如:Look up service
3. 追问NoSQL How to scale的原理

文件系统 vs 数据库系统

什么是文件系统?

操作:

输入: /home/jinyong/character_name.txt

输出 : 文件内容

如果有下面需求
找到“令狐冲”的“颜值”

1、打开文件

2、For循环扫描文件的内容
然后找令狐冲的颜值

```
{
{'姓名' : '令狐冲',    '颜值' : 5,    '身高' : '160cm'},
{'姓名' : '郭靖',      '颜值' : 9,    '身高' : '180cm'},
{'姓名' : '东邪',      '颜值' : 7,    '身高' : '170cm'},
}
```

/home/jinyong/character_name.txt

文件系统不足？

文件系统提供一些简单的读写文件操作

实际查询当中有复杂的查询需求：

比如：查询令狐冲颜值

查询颜值小于5的

所以我们需要一个更复杂的系统建立在文件系统之上

数据库系统

1、 建立在文件系统之上

2、负责组织把一些数据存到文件系统

3、对外的接口比较方便操作数据

设计数据库系统

Scenario
需求

查询： key （令狐冲 + 颜值）

返回： value （5）

因为后端系统通常给web server使用，Scenario比较单一

Storage
数据库怎么存储
以表的形式?

姓名	颜值	身高
令狐冲	5	160
郭靖	9	180
东邪	7	170

数据最终都会存到文件里面

```
{
{'姓名' : 'Linghuchong',    '颜值' : 5,    '身高' : '160cm'},
{'姓名' : 'Guojing',    '颜值' : 9,    '身高' : '180cm'},
{'姓名' : 'Dongxie',    '颜值' : 7,    '身高' : '170cm'},
}
```

从文件系统基础上思考搭建数据库系统

在文件里面
怎么更好支持查询操作?

```
{
{'姓名' : 'Linghuchong',   '颜值' : 5,   '身高' : '160cm'},
{'姓名' : 'Guojing',   '颜值' : 9,   '身高' : '180cm'},
{'姓名' : 'Dongxie',   '颜值' : 7,   '身高' : '170cm'},
}
```

先读取文件到内存里面
然后排序+二分查询？

有什么问题？

直接在硬盘中对数据进行排序 + 硬盘中二分？

那么怎么在硬盘里面进行排序和二分呢？

查询解决了，
有一天令狐冲整容了怎么办？

查询解决了，有一天令狐冲整容了怎么办？

修改令狐冲颜值，从5变到6

1. 直接在文件里面修改
2. 读取整个文件，修改好了，把原文件删除，重新写入新文件
3. 不修改，直接append操作追加一条记录“令狐冲颜值=6”在文件最后面

修改文件内容

1. 直接在文件里面修改
   很难做到直接修改内容，如果原来是4个字节，现在修改成8个字节，那么之后的内容都需要移动位置。

2. 读取整个文件，修改好了，把原文件删除，重新写入新文件
   非常耗费时间，每次要读出写入 其他多余不变的内容

3. 不修改，直接append操作追加一条记录“令狐冲颜值=6”在文件最后面
   好处： 特别快

BigTable为了写优化
选择了直接Append

坏处： 读取数据怎么办：1.怎么识别哪个是最新的记录 2.没有顺序怎么二分？

怎么识别哪个是最新的记录？

时间戳

时间戳最大的那个就是真正的数据

没有顺序怎么二分？

分块有序

1. 每一块都是内部有序
2. 写的时候只有最后一块是无序的，并且隔一段时间整理成有序

块会越写越多，会有很多重复

(令狐冲经常做整形手术)

重复非常多

每次查询所有的块非常消耗时间

定期K路归并

http://www.lintcode.com/en/problem/merge-k-sorted-arrays/

完整系统读/写过程

One Work Solution

写入过程

写入过程

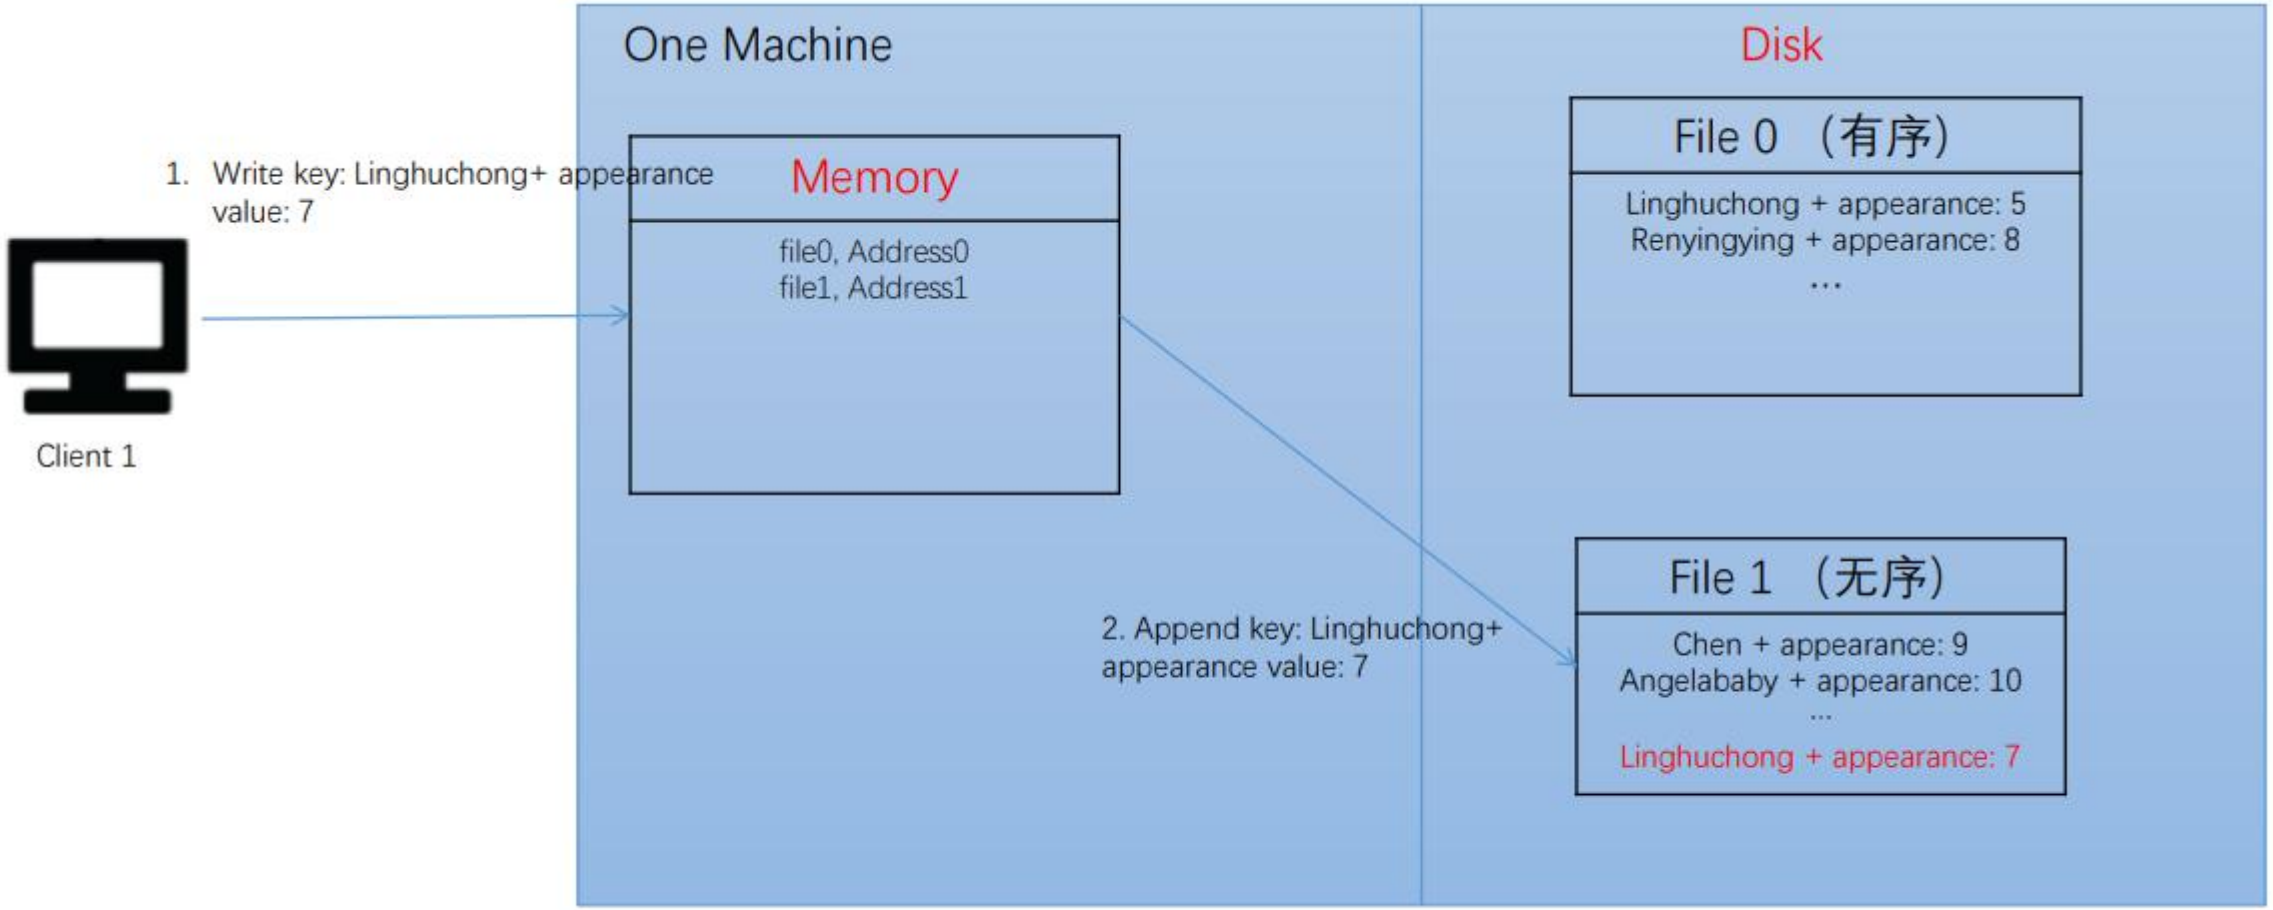

怎么把最后一个File从无序变成有序?

1. 读入到内存快速排序
2. 硬盘外部排序
3. 可不可以一开始就存在内存里面?

1. 读入到内存快速排序。
   所有数据1次硬盘写入，1次硬盘统一读取+内存排序+1次硬盘统一写入

2. 硬盘外部排序
   有必要么？

3. 可不可以一开始就存在内存里面？
   内存排序+1次硬盘写入

写入过程

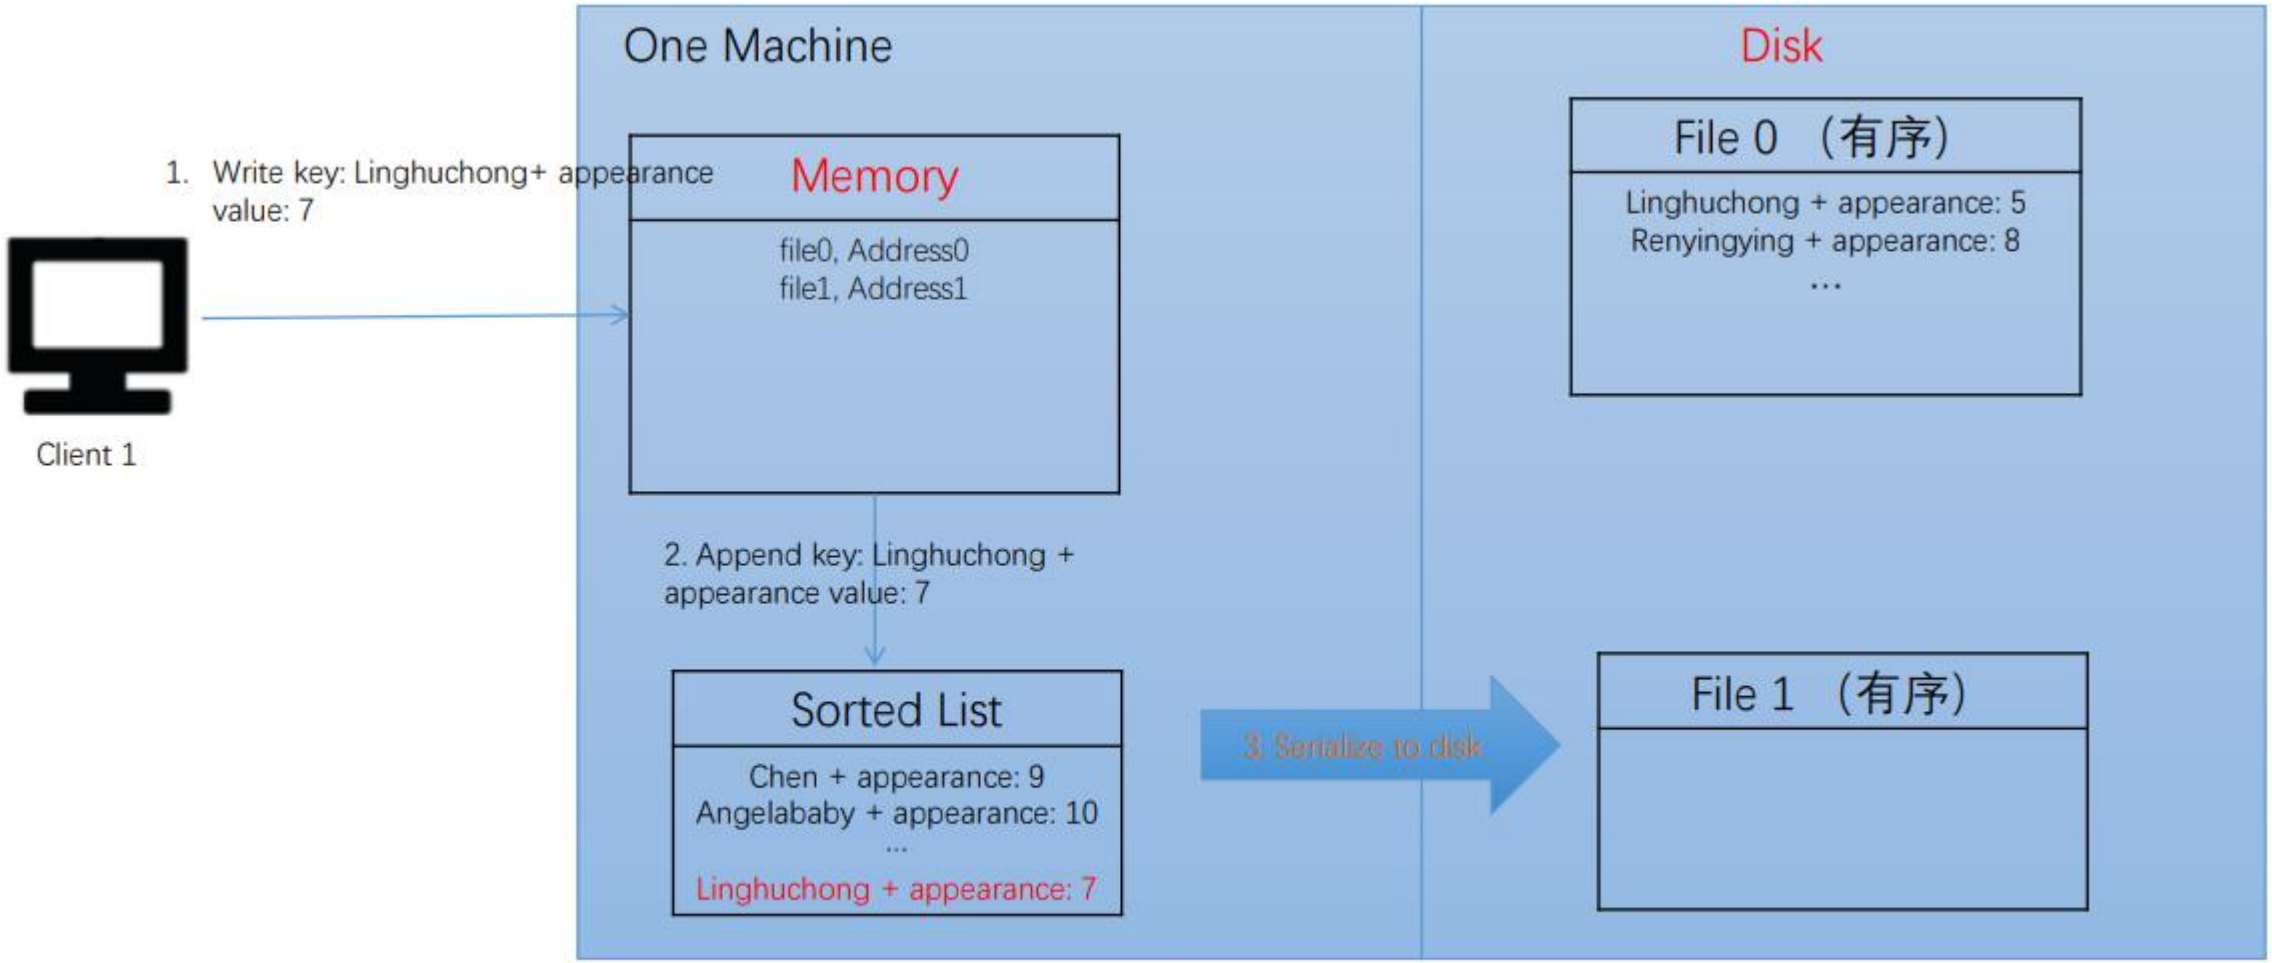

Serialization

http://www.lintcode.com/en/problem/binary-tree-serialization/

Interviewer: 机器挂了，内存没了？

Write Ahead Log (WAL)

那写log岂不是又要写硬盘

WAL 非常方便,不像重要数据需要整理

内存排序+1次硬盘统一写入+1次硬盘写Log

Link: http://www.larsgeorge.com/2010/01/hbase-architecture-101-write-ahead-log.html

读出过程

读出过程

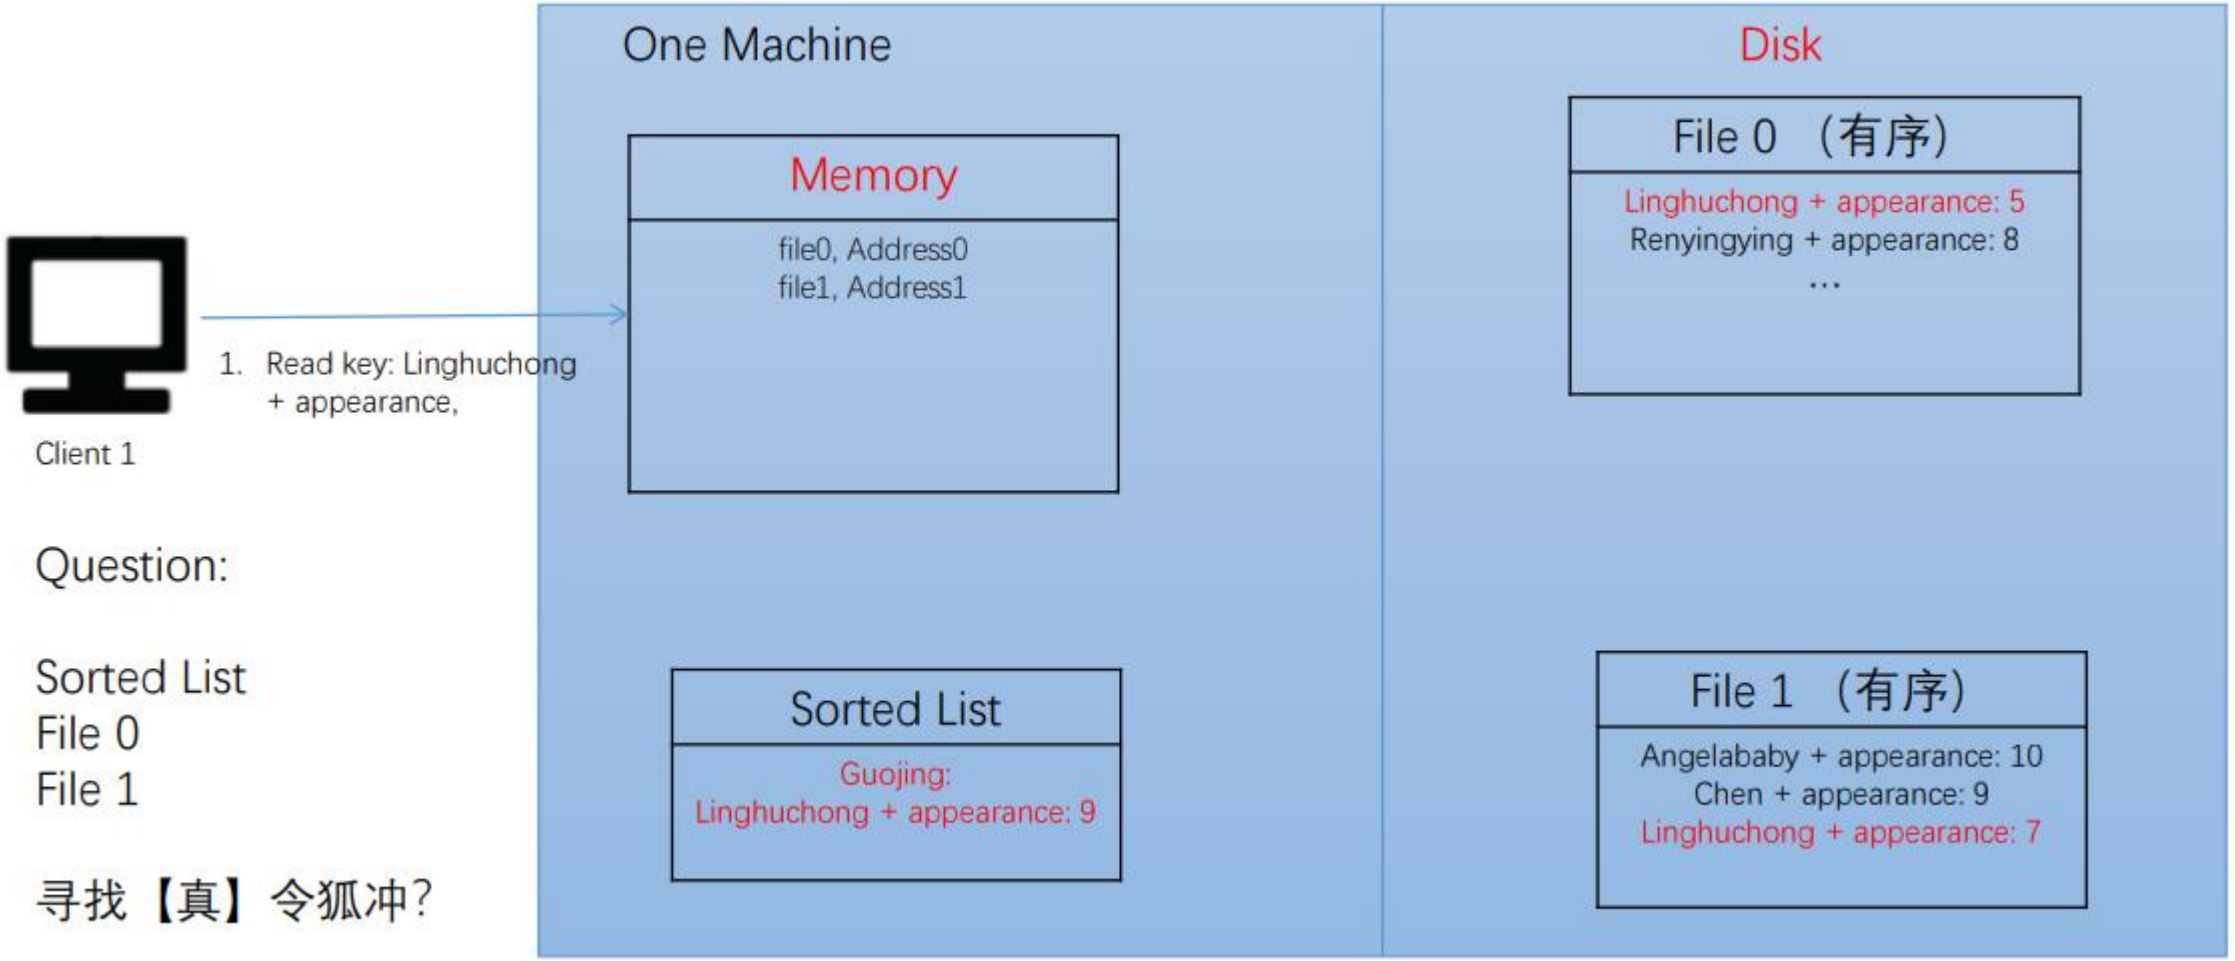

读出过程

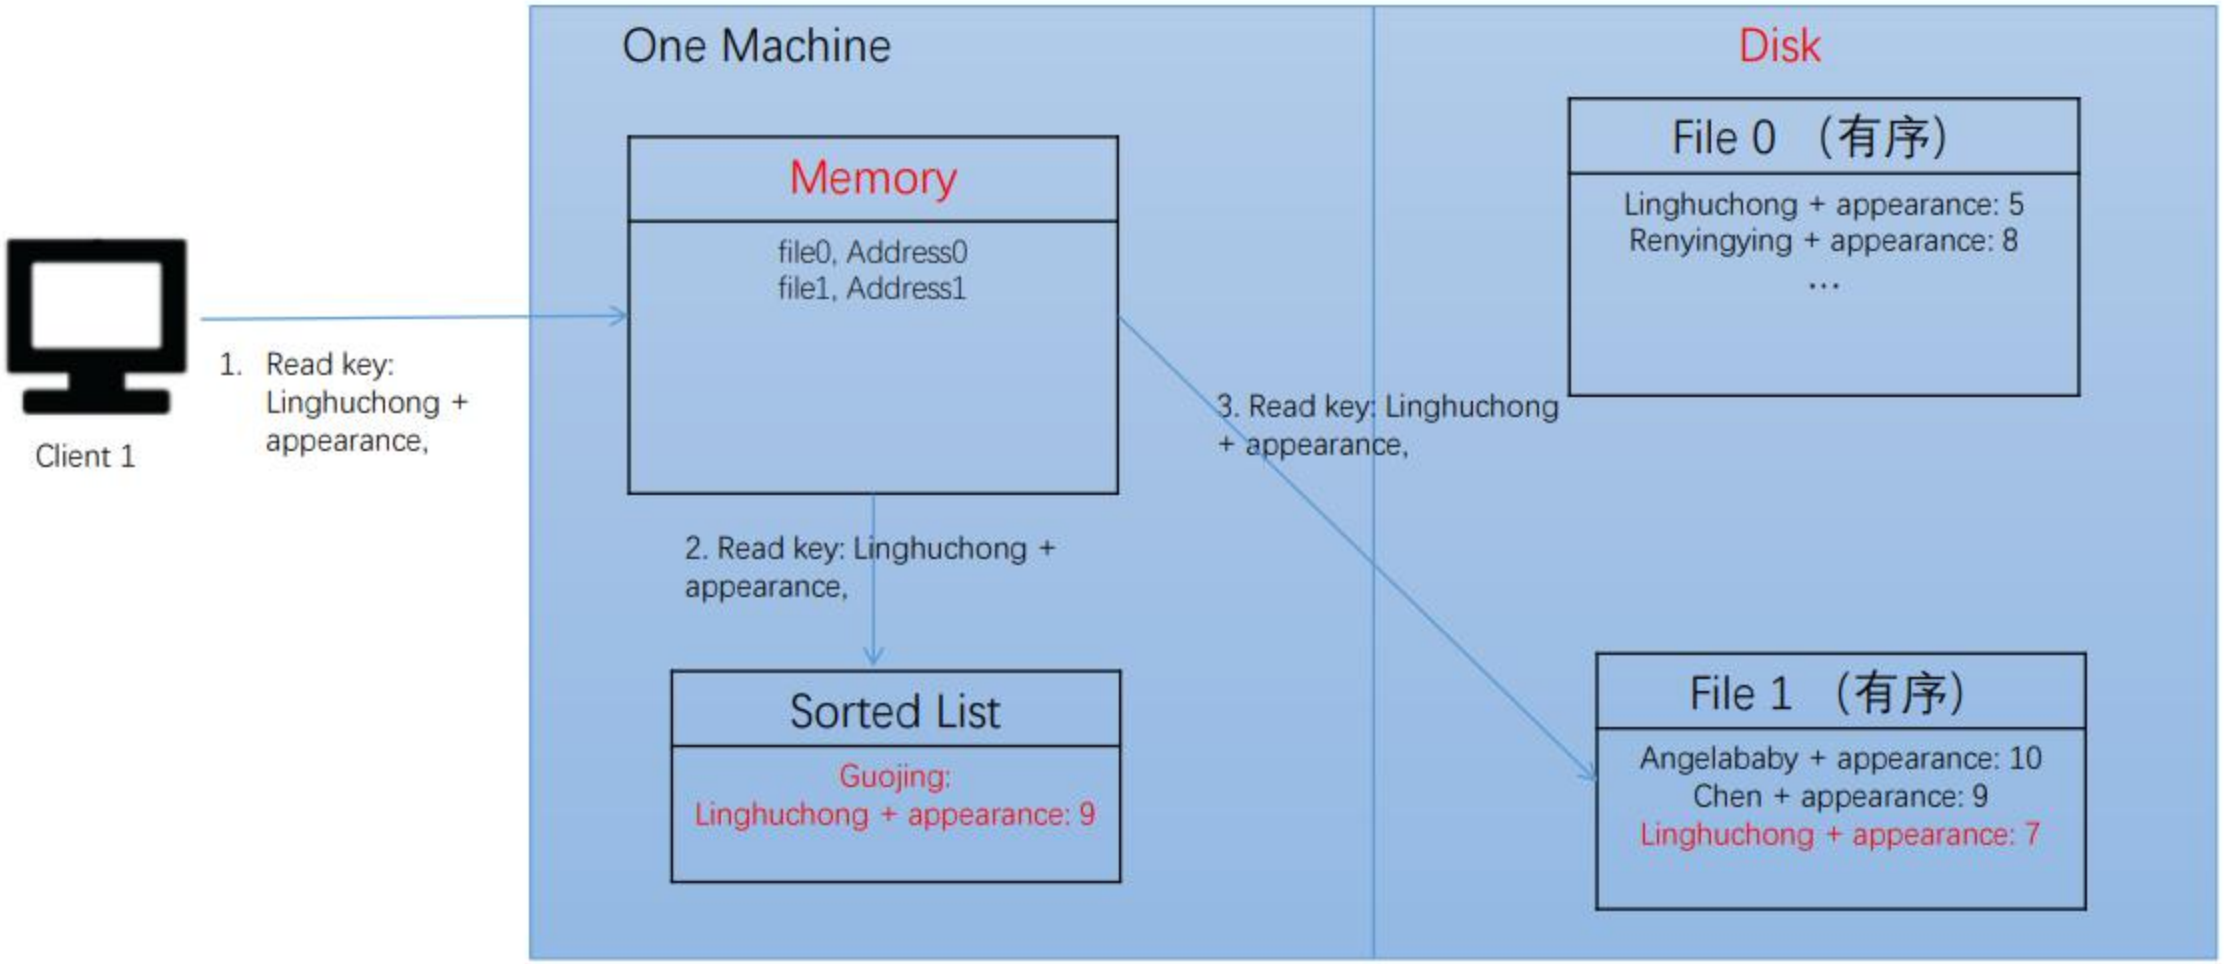

一个File里面怎么查询令狐冲？

1. 硬盘二分
2. 有没有更好的方法？

建立Index

目的： 加快查询

怎么建?

One easy way to build index

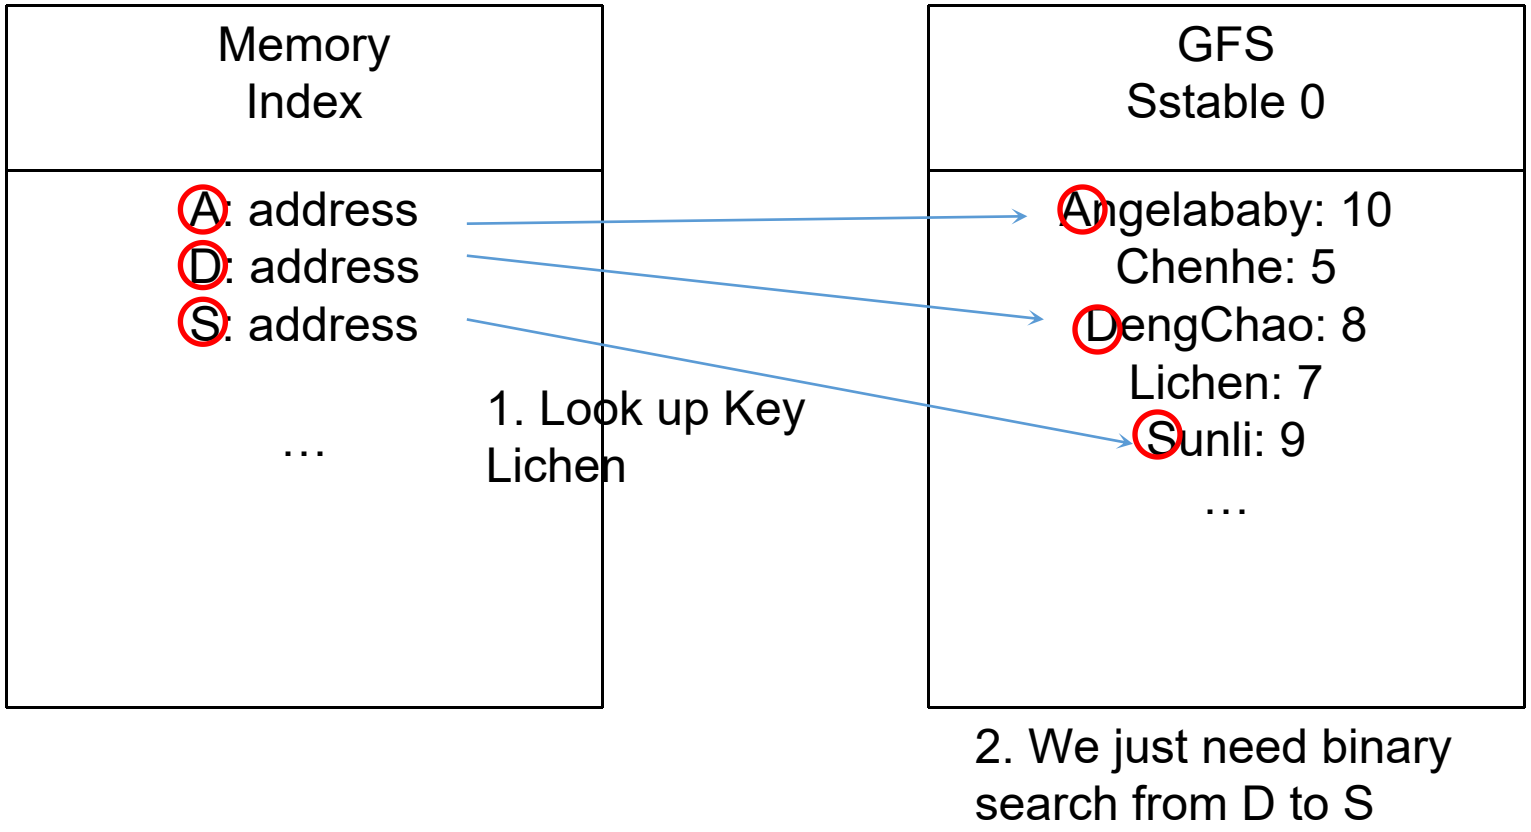

Key

- 把一些Key放入内存作为Index
- Index有效减少磁盘读写次数

Intersection of Two Arrays ii Follow Up

http://www.lintcode.com/en/problem/intersection-of-two-arrays-ii/

这道题的challenge题目

Read More:

B tree index: http://bit.ly/2bTwhZC

有木有更好的方法检查一个key在不在一个File里面？

为什么要做如此多的读优化?

因为在写的时候做了Append优化，才会想办法加快读的速度。

BloomFilter

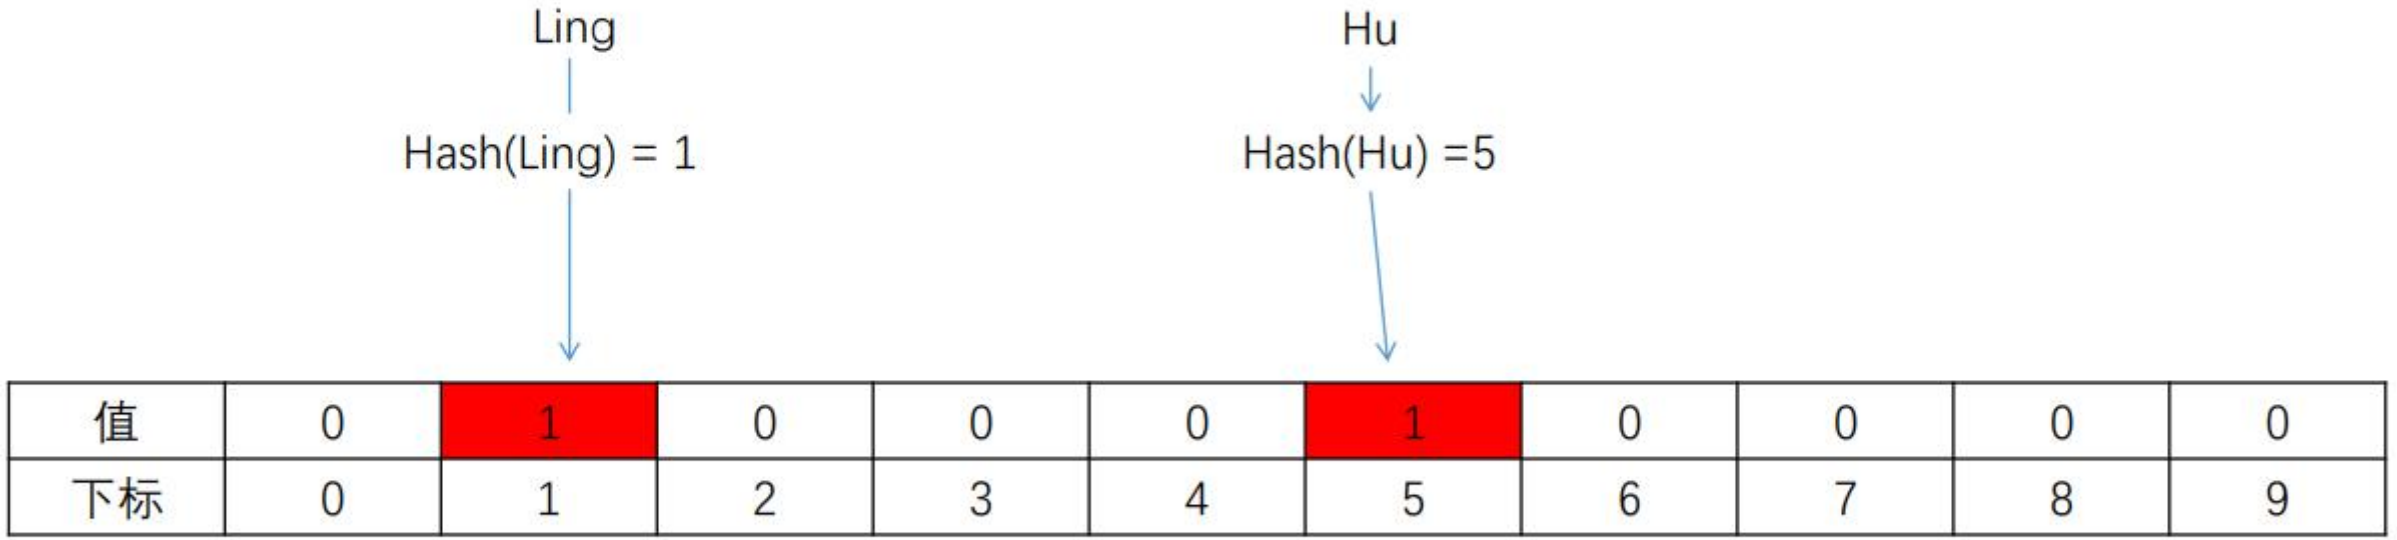

值	0	1	0	0	0	1	0	0	0	0
下标	0	1	2	3	4	5	6	7	8	9

块中的Key: Ling Hu

Interview: How to build bloom filter?

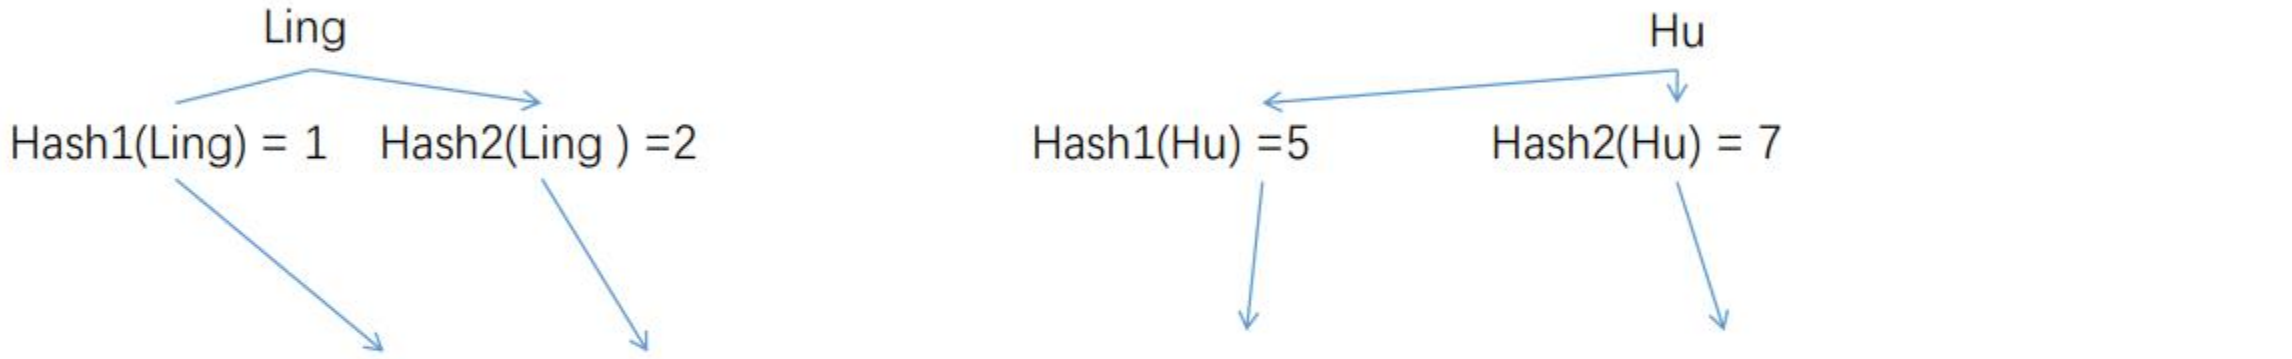

值	0	1	1	0	0	1	0	1	0	0
下标	0	1	2	3	4	5	6	7	8	9

块中的Key: Ling Hu

Interview: How to build bloom filter?

- 如何检查“chen” 在bloom filter 里面?

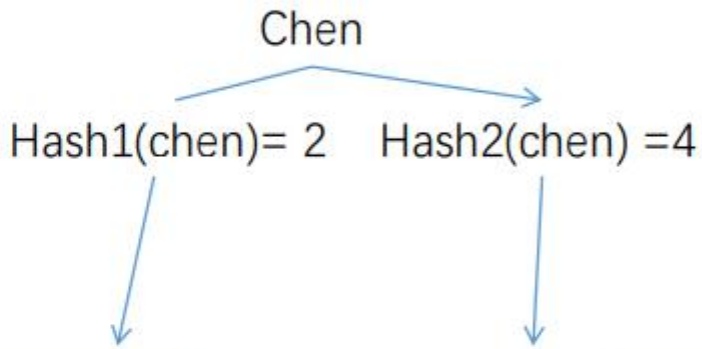

值	0	1	1	0	0	1	0	1	0	0
下标	0	1	2	3	4	5	6	7	8	9

块中的Key: Ling Hu

Interview: How to build bloom filter?

- 如何检查“sun” 在bloom filter 里面?

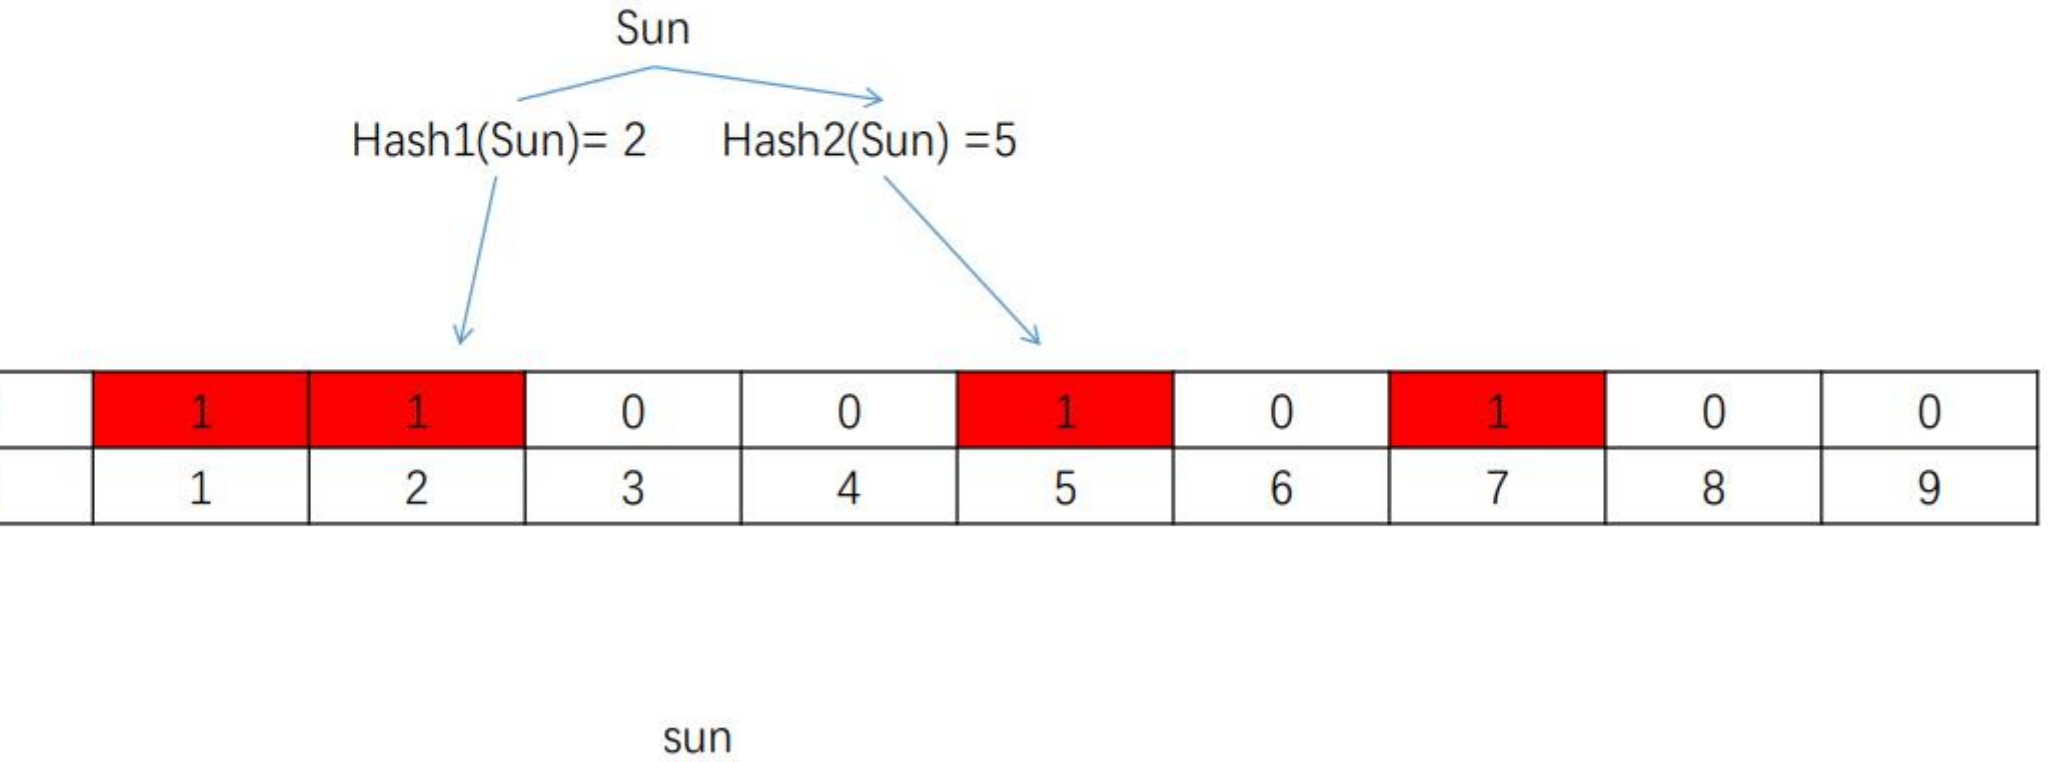

Bloom Filter 误判率

False is always False.

True may be True.

How many false is hidden in true?

Bloom Filter精确度跟什么有关?

1. 哈希函数个数
2. 位数组长度
3. 加入的字符串数目

Bloom Filter 误判率

举个例子如果

哈希函数的个数15个、

位数组大小200w、

加入的字符串数量10w个的话、

判断2000w个新的字符串

误判率在 3~4% 左右

计算误判率公式: https://en.wikipedia.org/wiki/Bloom_filter

完整的读出过程(with Index, BF)

读出过程

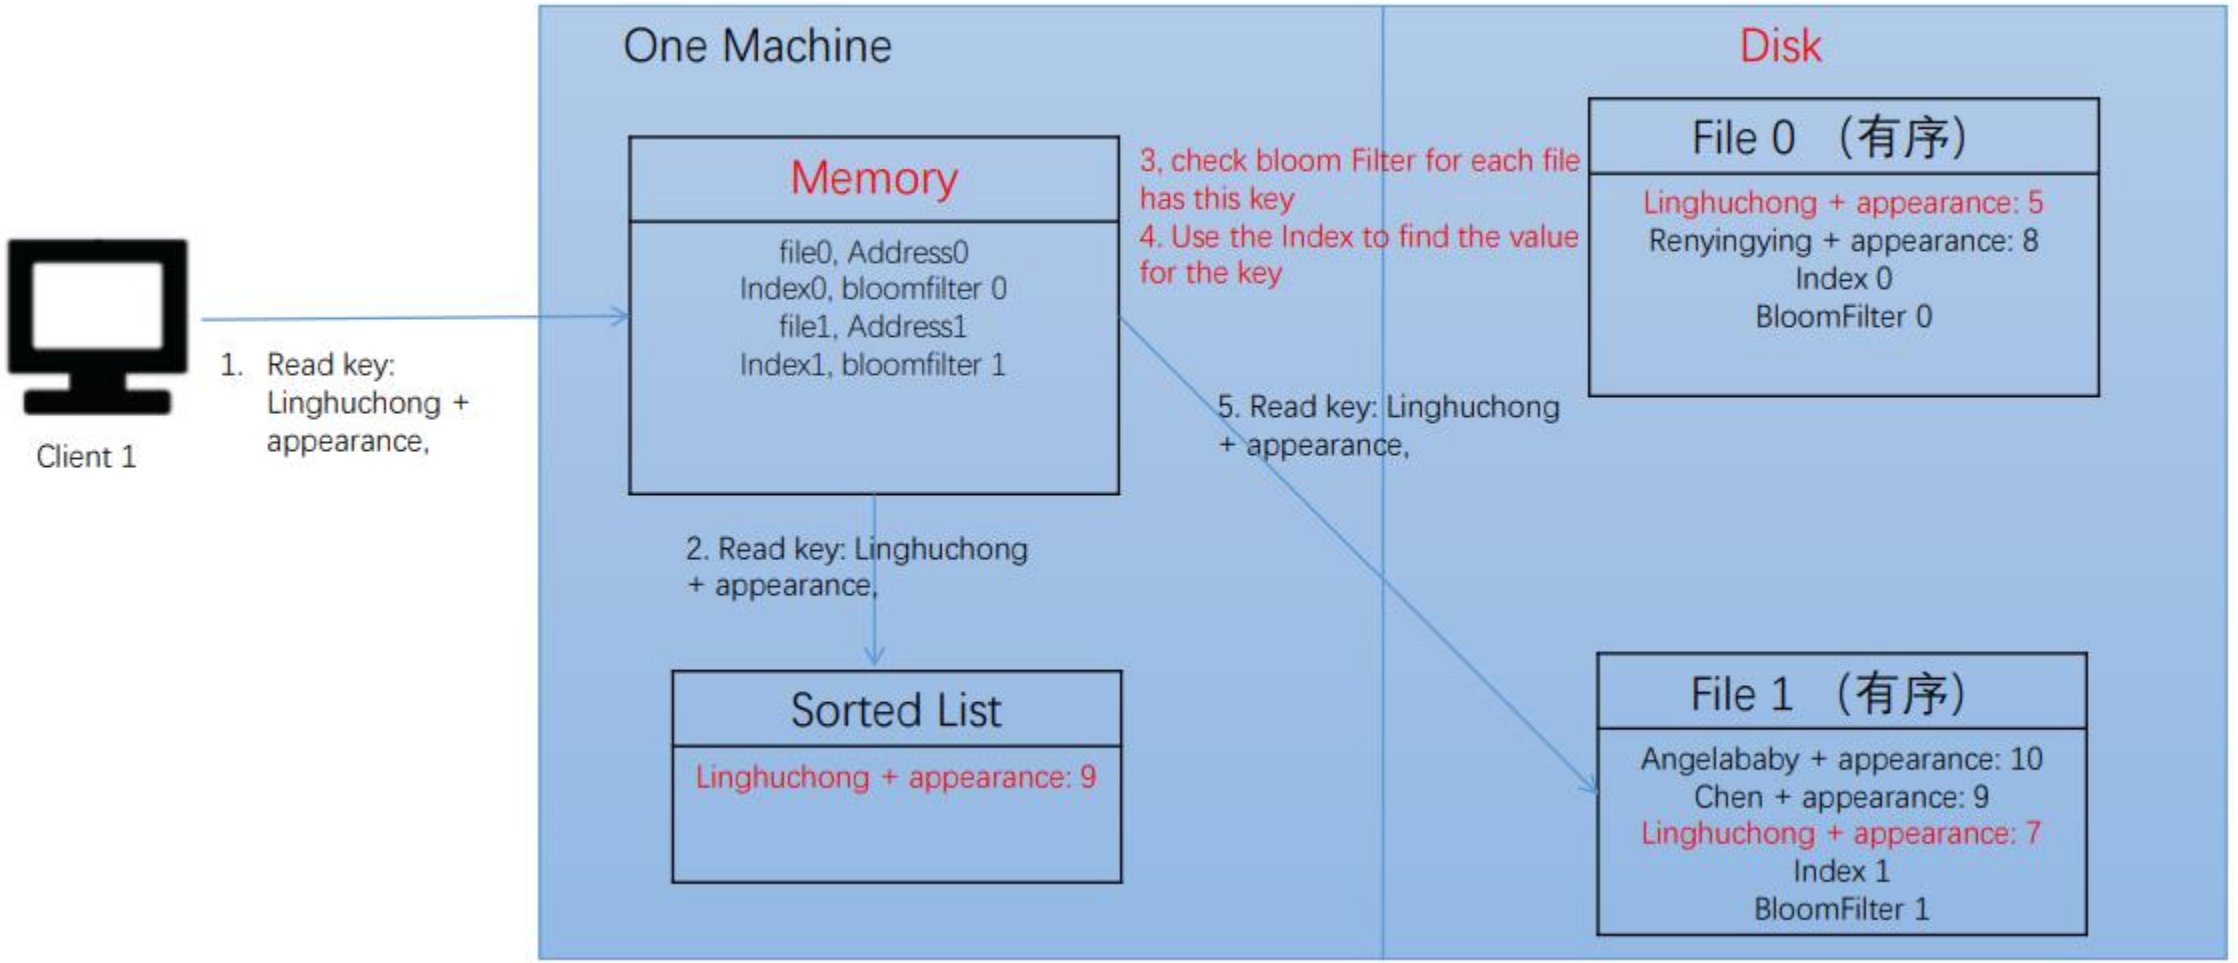

Specific Name in BigTable

String is Store in the File.

SSTable = Sorted String Table

Sorted List 用 Skip List 实现

拓展阅读

1. Skip List

   Code: https://github.com/petegoodliffe/skip_list

   Wiki: http://bit.ly/2g0C29a

2. SSTable

   Google SSTable Page: http://bit.ly/1kqwrFe

写入过程

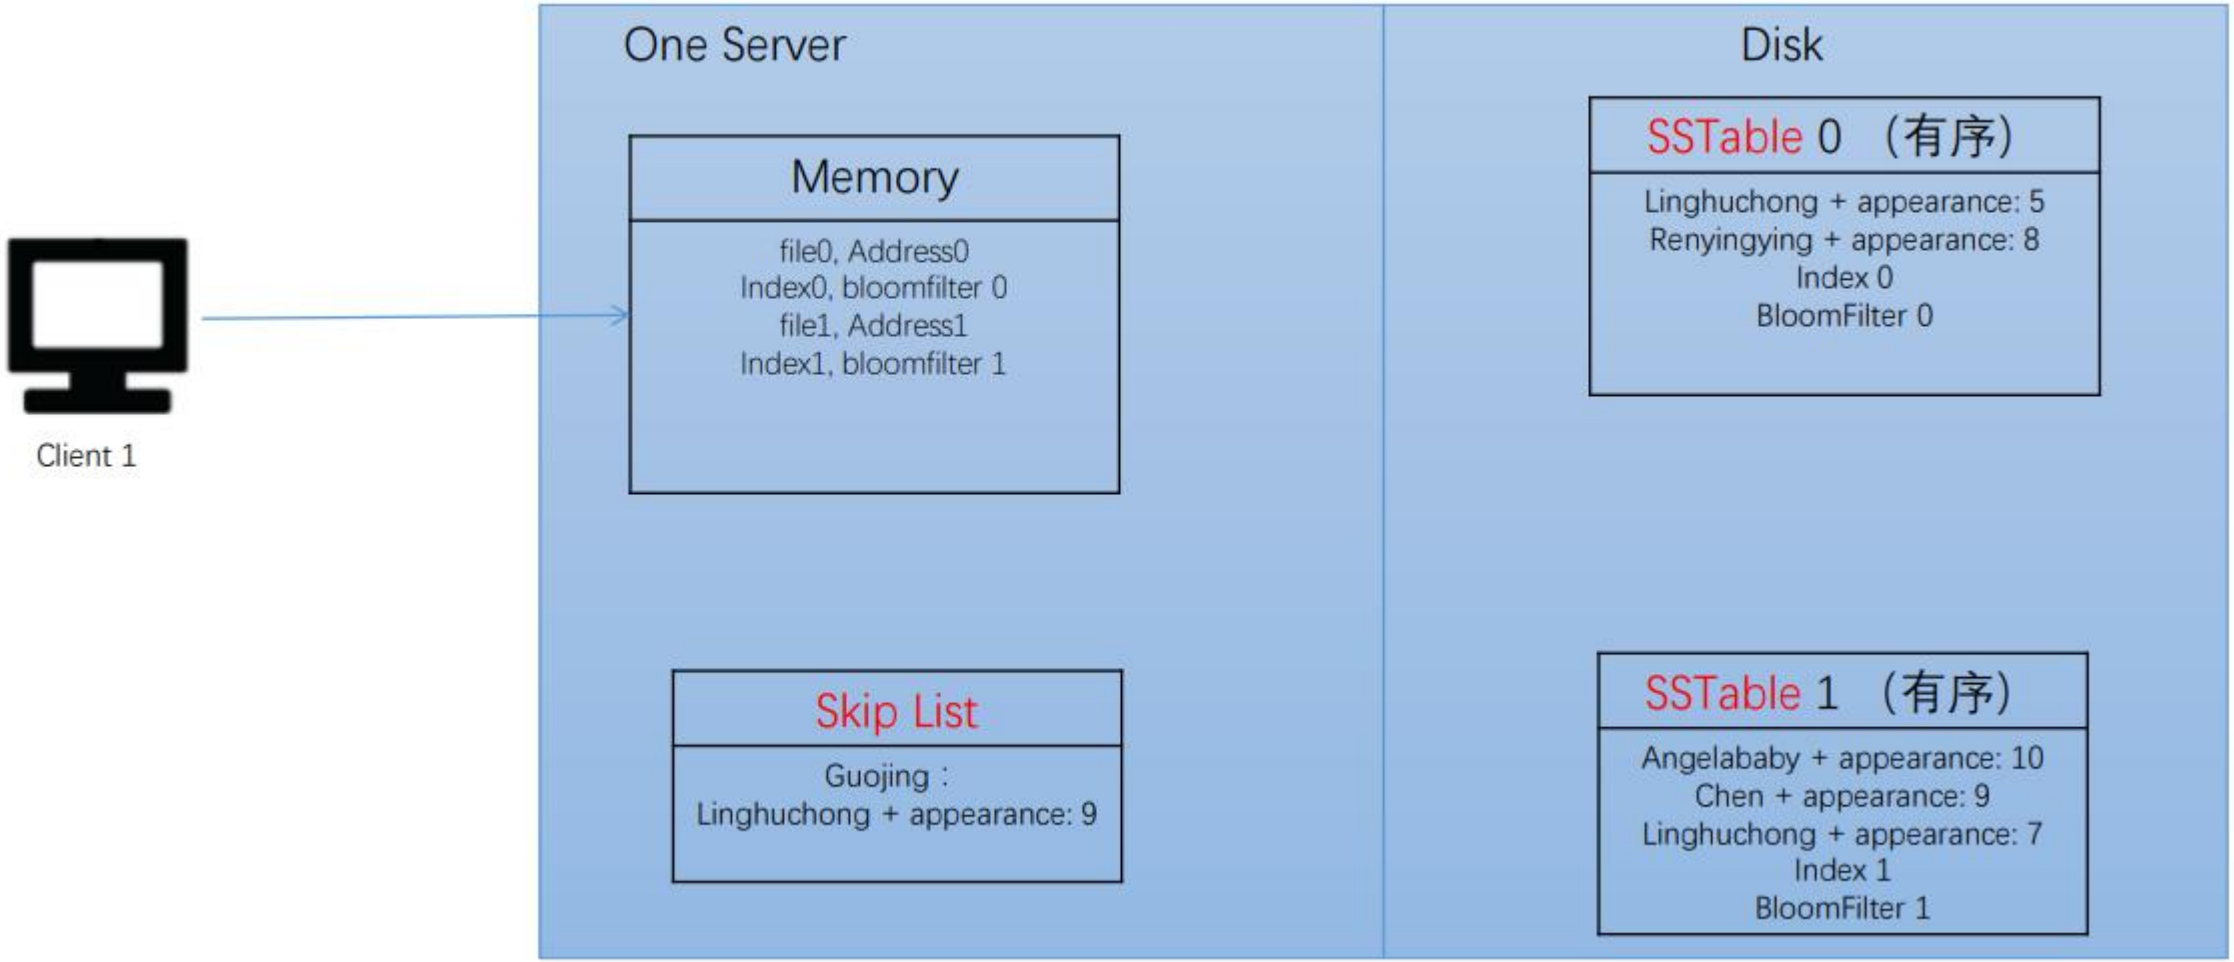

我们已经学会了一台机器BigTable的操作

读/写

Key: 令狐冲+颜值

Value: 5

姓名	颜值	身高
令狐冲	5	160
郭靖	9	180
东邪	7	170

Interviewer: How to read/write key: value from 1PB file

Scale

Sharding?

姓名	颜值	身高
令狐冲	5	160
郭靖	9	180
东邪	7	170

Sharding

Vertical Sharding?

Horizontal Sharding?

难点：取令狐冲“颜值”是不是会取“身高”，“武功”相关属性

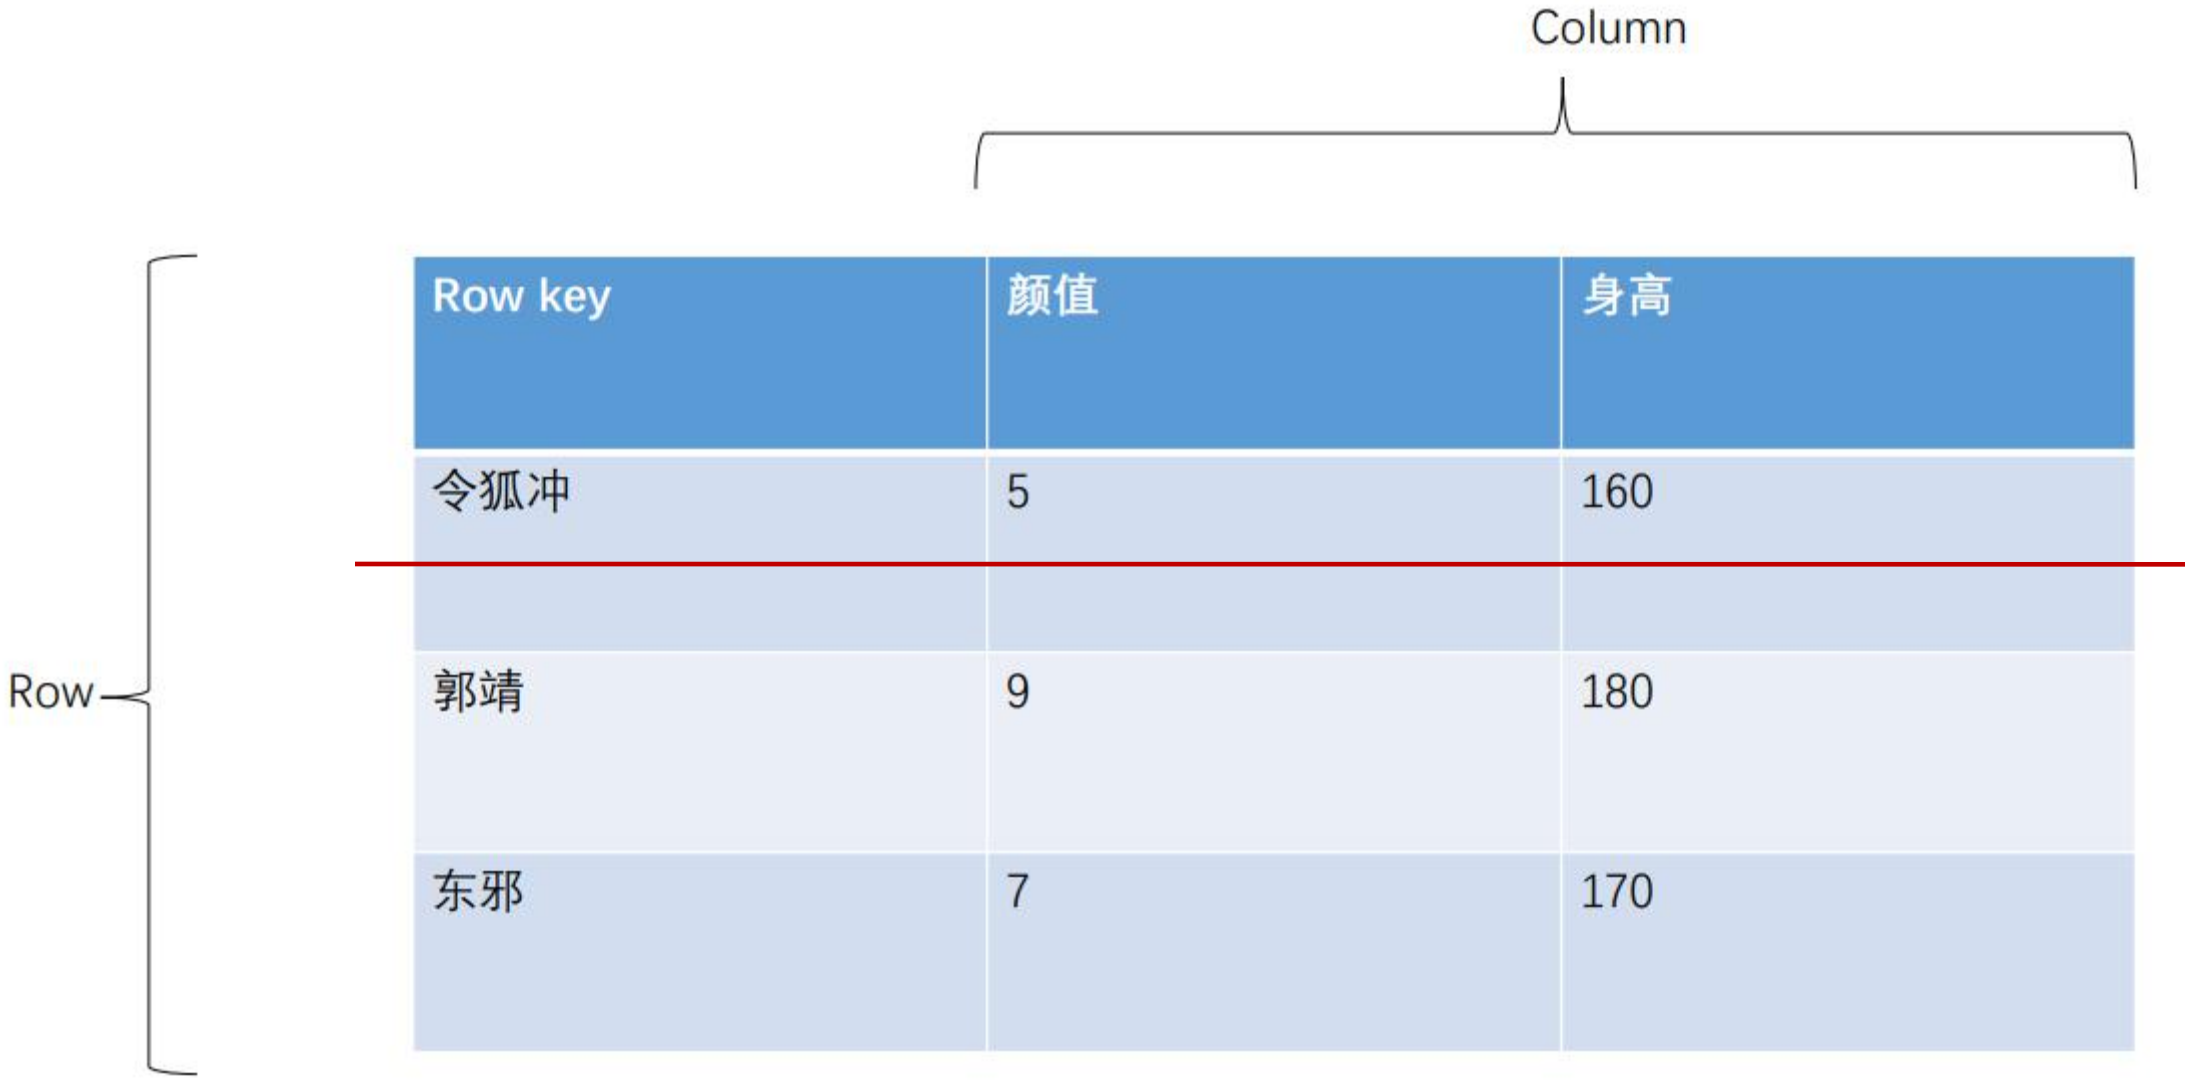

Row key	颜值	身高
令狐冲	5	160
郭靖	9	180
东邪	7	170

	颜值	身高
令狐冲	5	160
郭靖	9	180
东邪	7	170

Consistent Hash(row key: 姓名)

表1	颜值	身高
令狐冲	5	160

表2	颜值	身高
郭靖	9	180
东邪	7	170

一台机器搞不定，那么需要多台机器了

Master + Slave

Interviewer: How to manager server?

- Key
  - Master + Slave
  - Master has HashMap [key, server address]

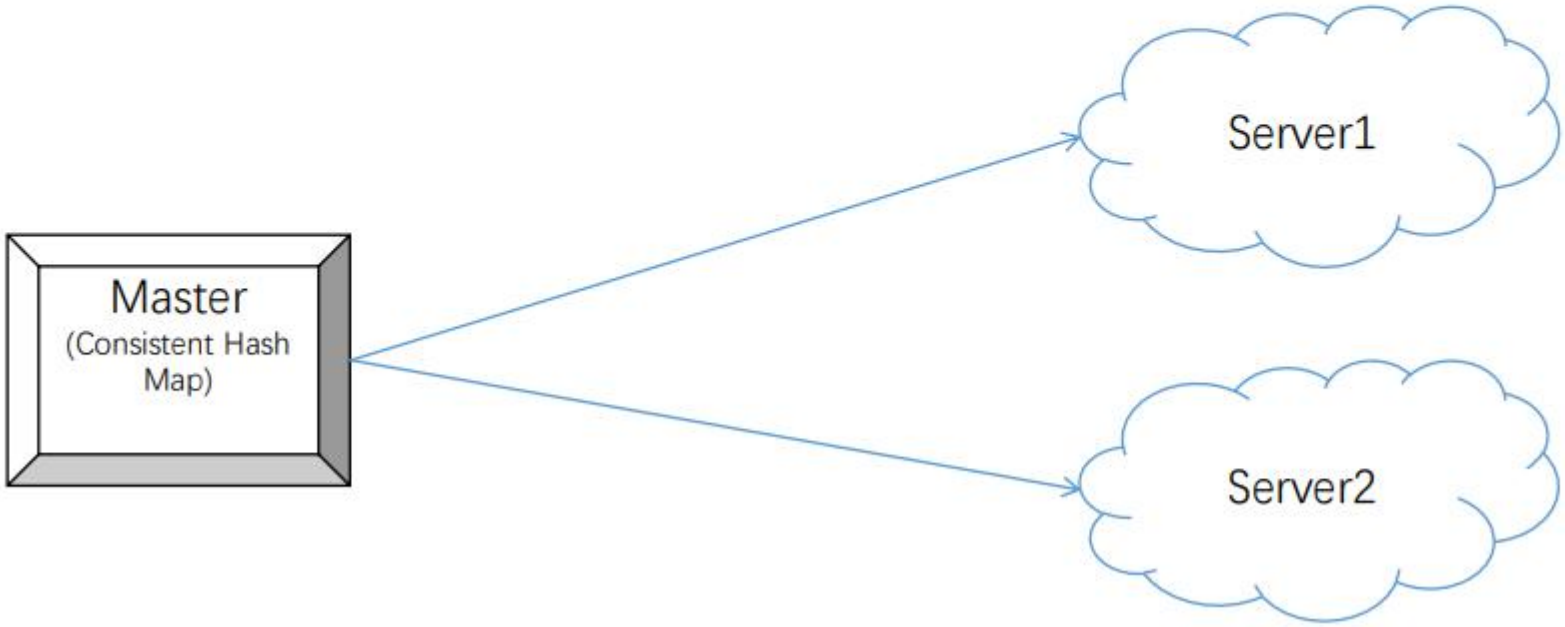

Interview: How do we read in BigTable with multi-server

Interview: How to read a key? （宏观）

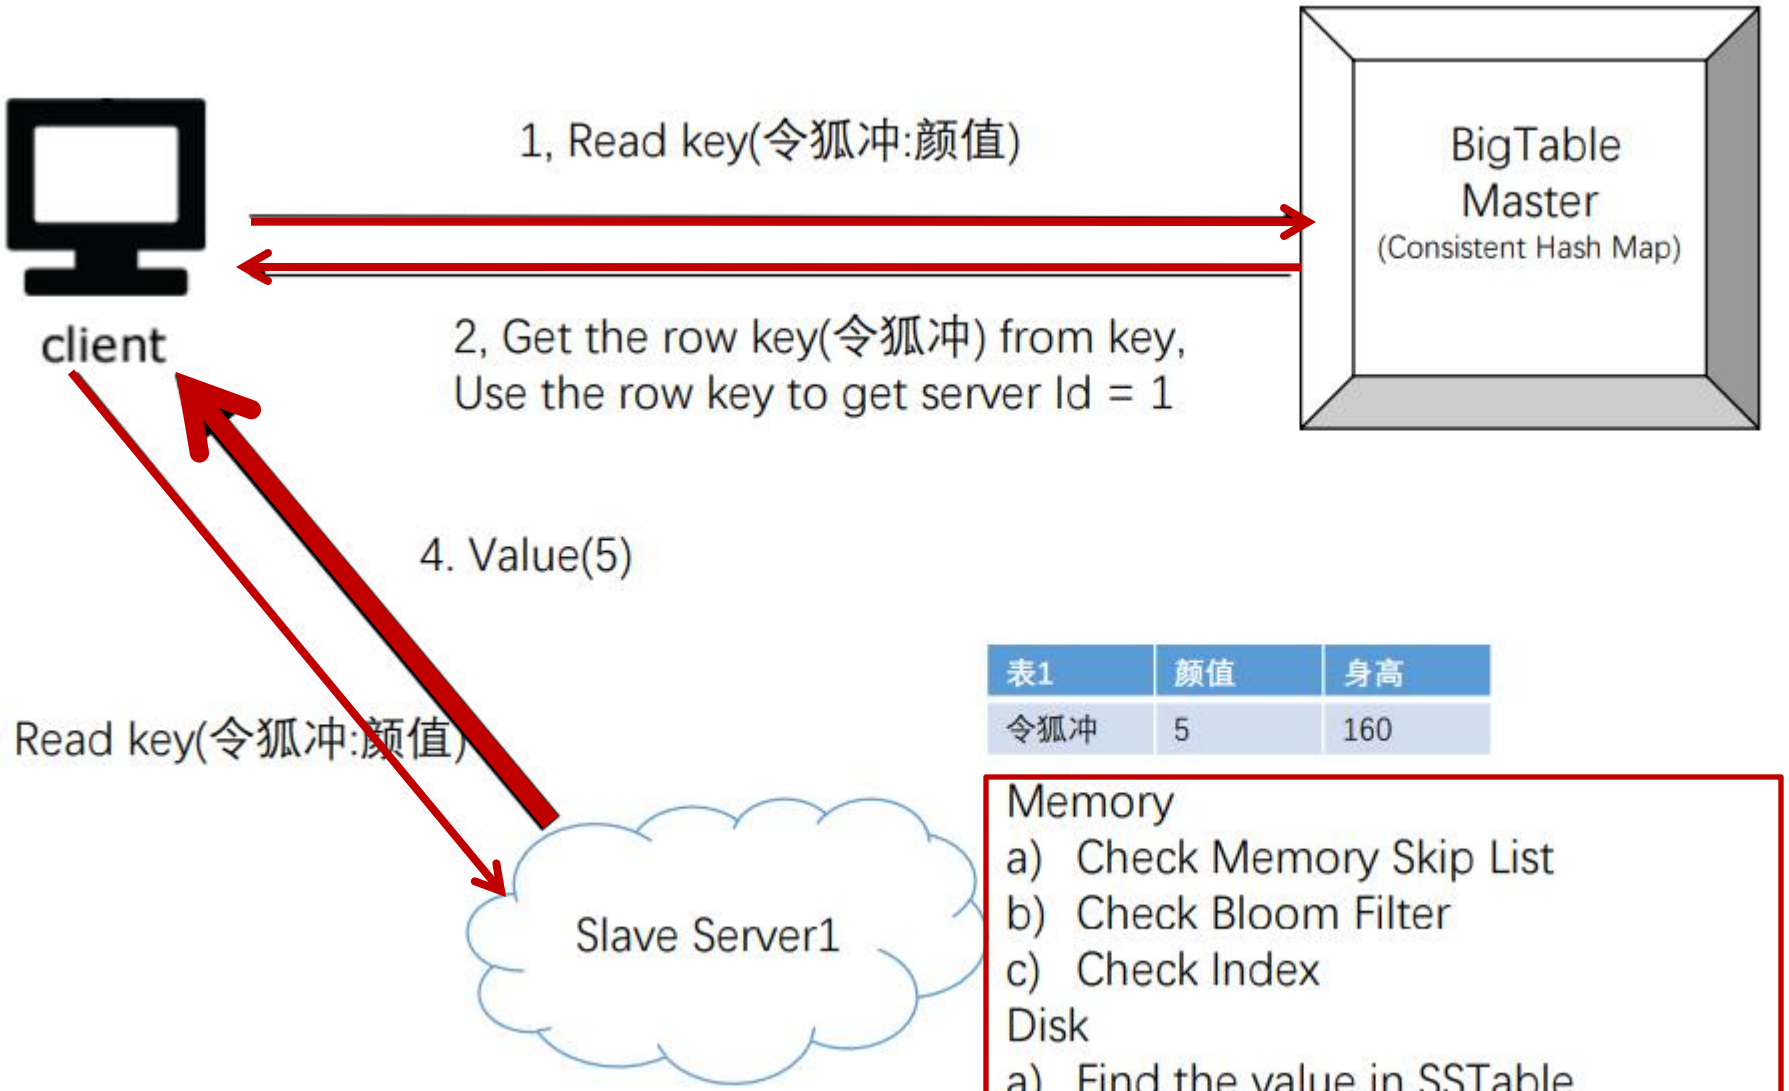

表1	颜值	身高
令狐冲	5	160

Interviewer: How do we write BigTable?

Interview: How to write a key? (宏观)

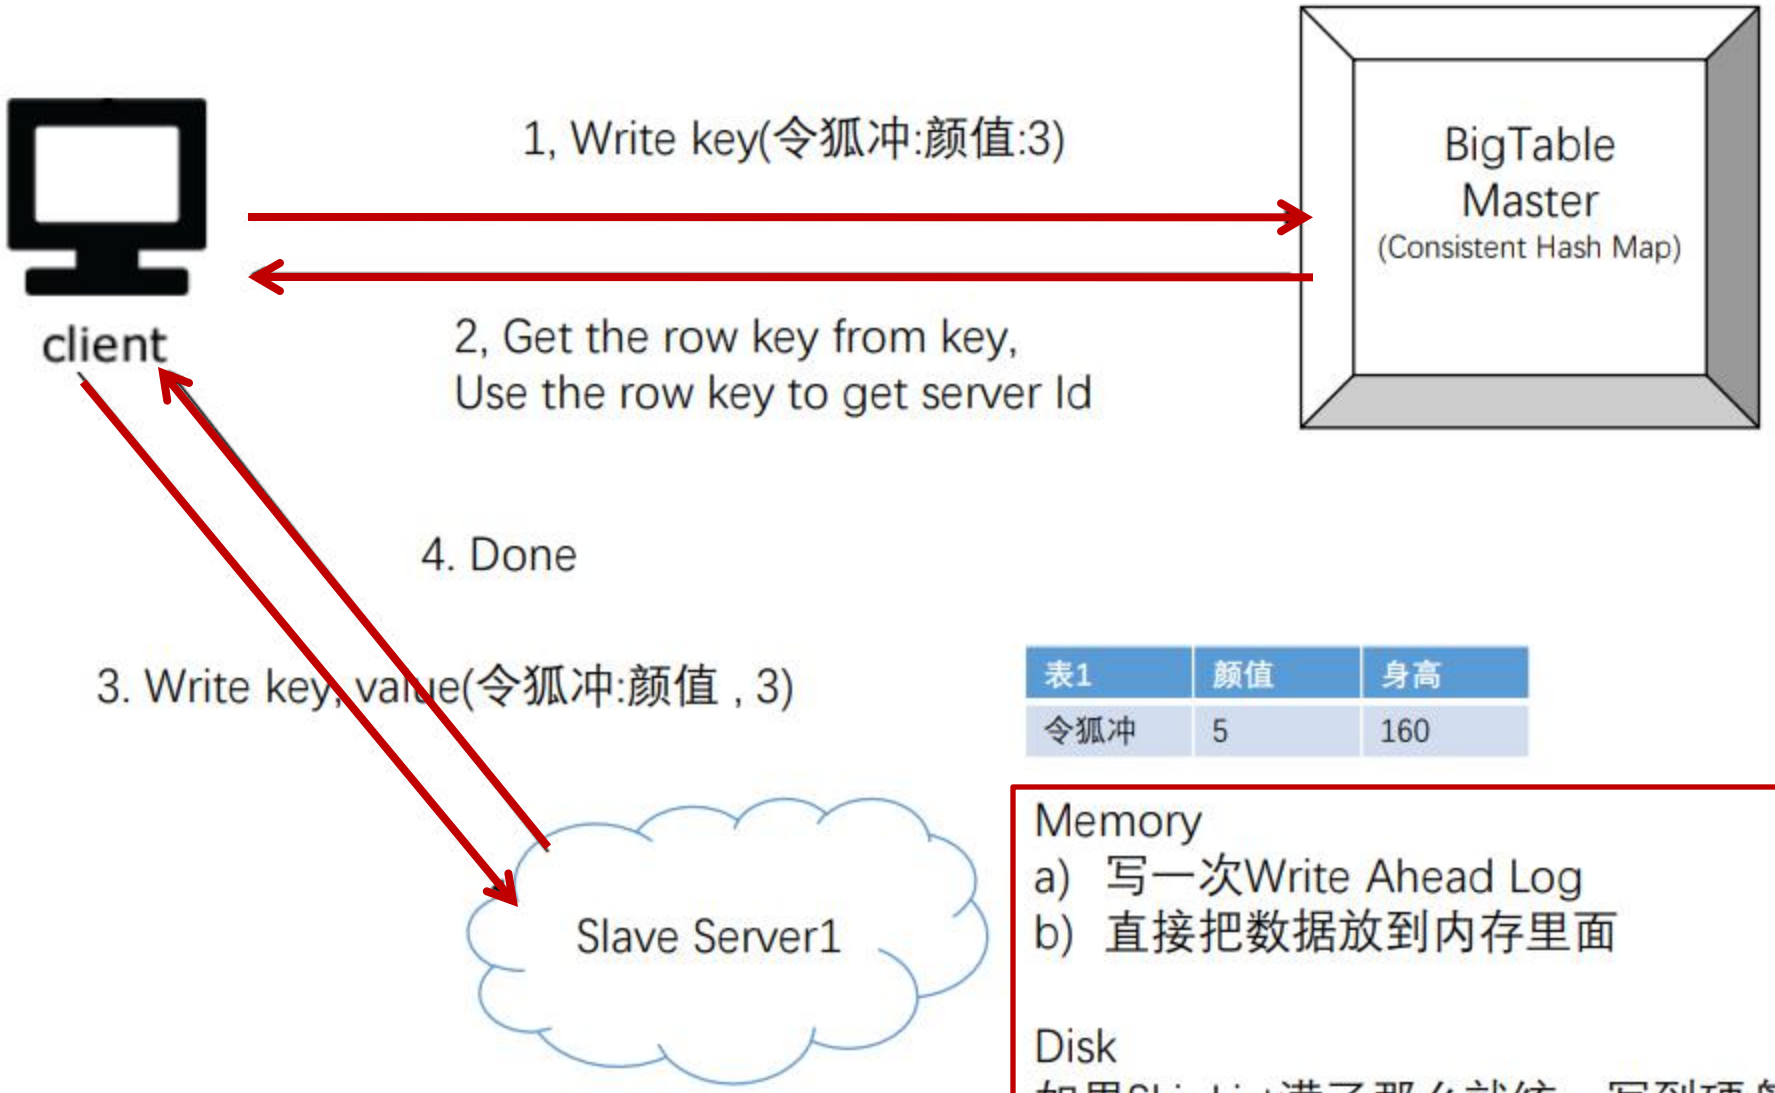

表1	颜值	身高
令狐冲	5	160

Memory
a) 写一次Write Ahead Log
b) 直接把数据放到内存里面

Disk
如果SkipList满了那么就统一写到硬盘

Interviewer: 每台机器数据越写越多存不下怎么办?

现在所有的数据都存在Slave Server local disk里面

把所有数据存到GFS里面

Advantage:

1. Disk Size
2. Replica
3. Failure and Recovery

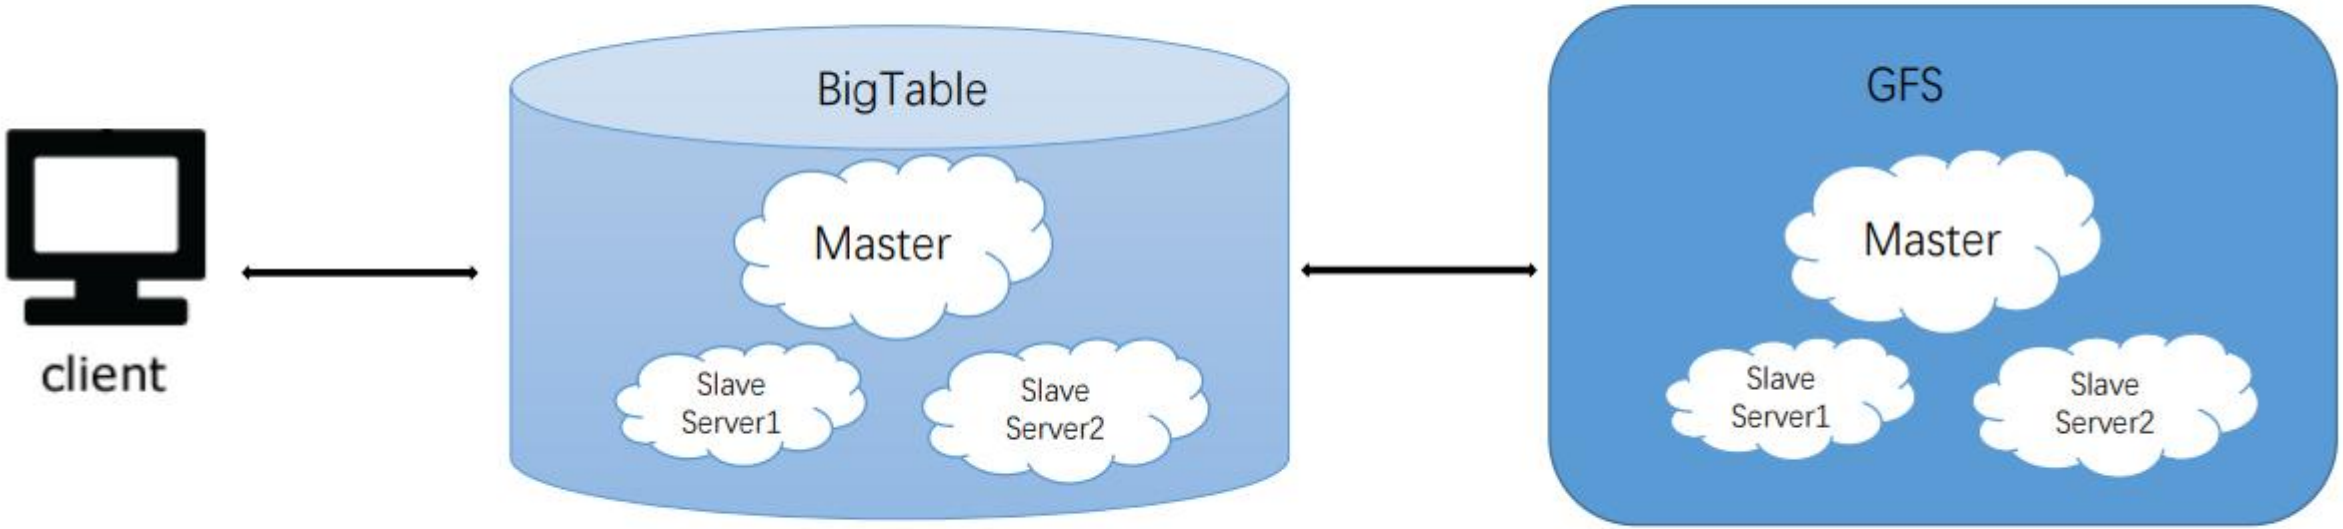

BigTable vs GFS

都是Master + Slave

是否就用一个Master + Slave把两个都实现了？

BigTable Naming

What is Tablet

	颜值	身高
令狐冲	5	160
郭靖	9	180
东邪	7	170

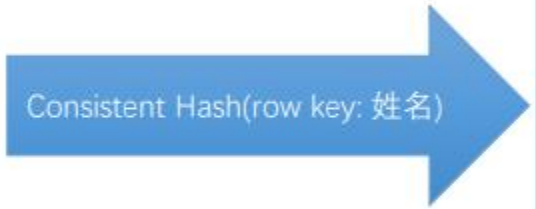

表1	颜值	身高
令狐冲	5	160

表2	颜值	身高
郭靖	9	180
东邪	7	170

What is Tablet Server

Tablet Server = Store Tablet Slave Server

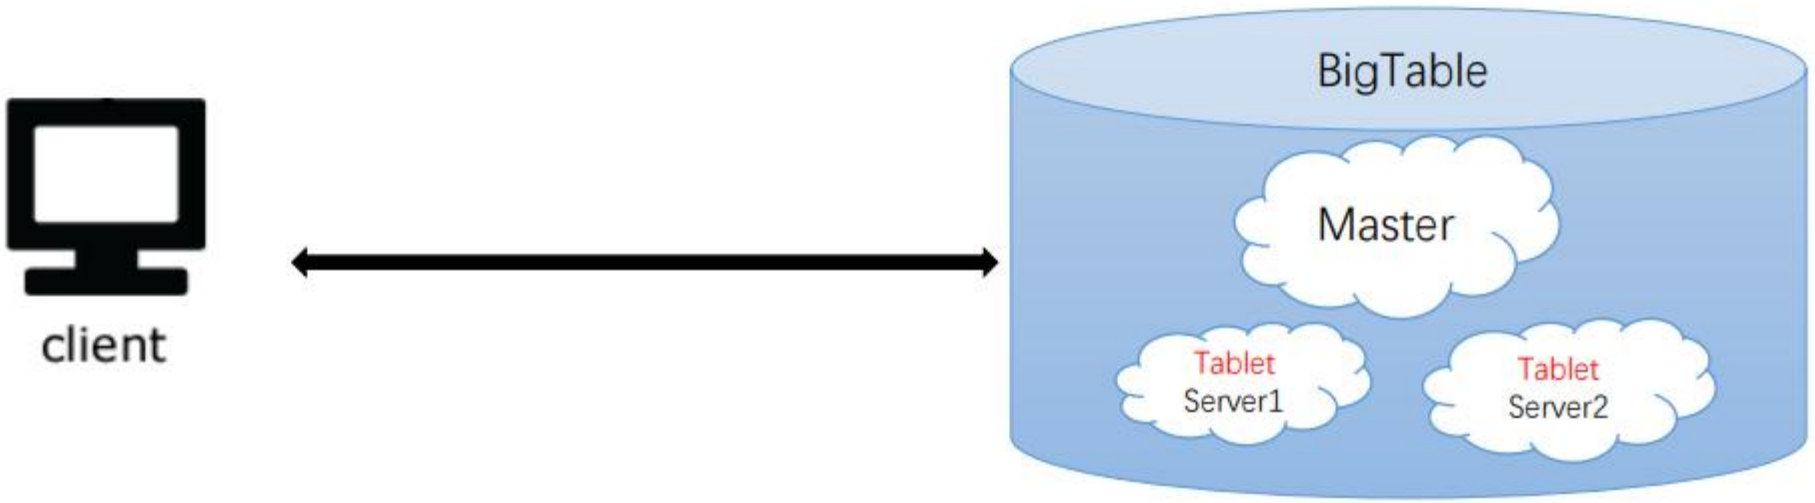

Tablet Server

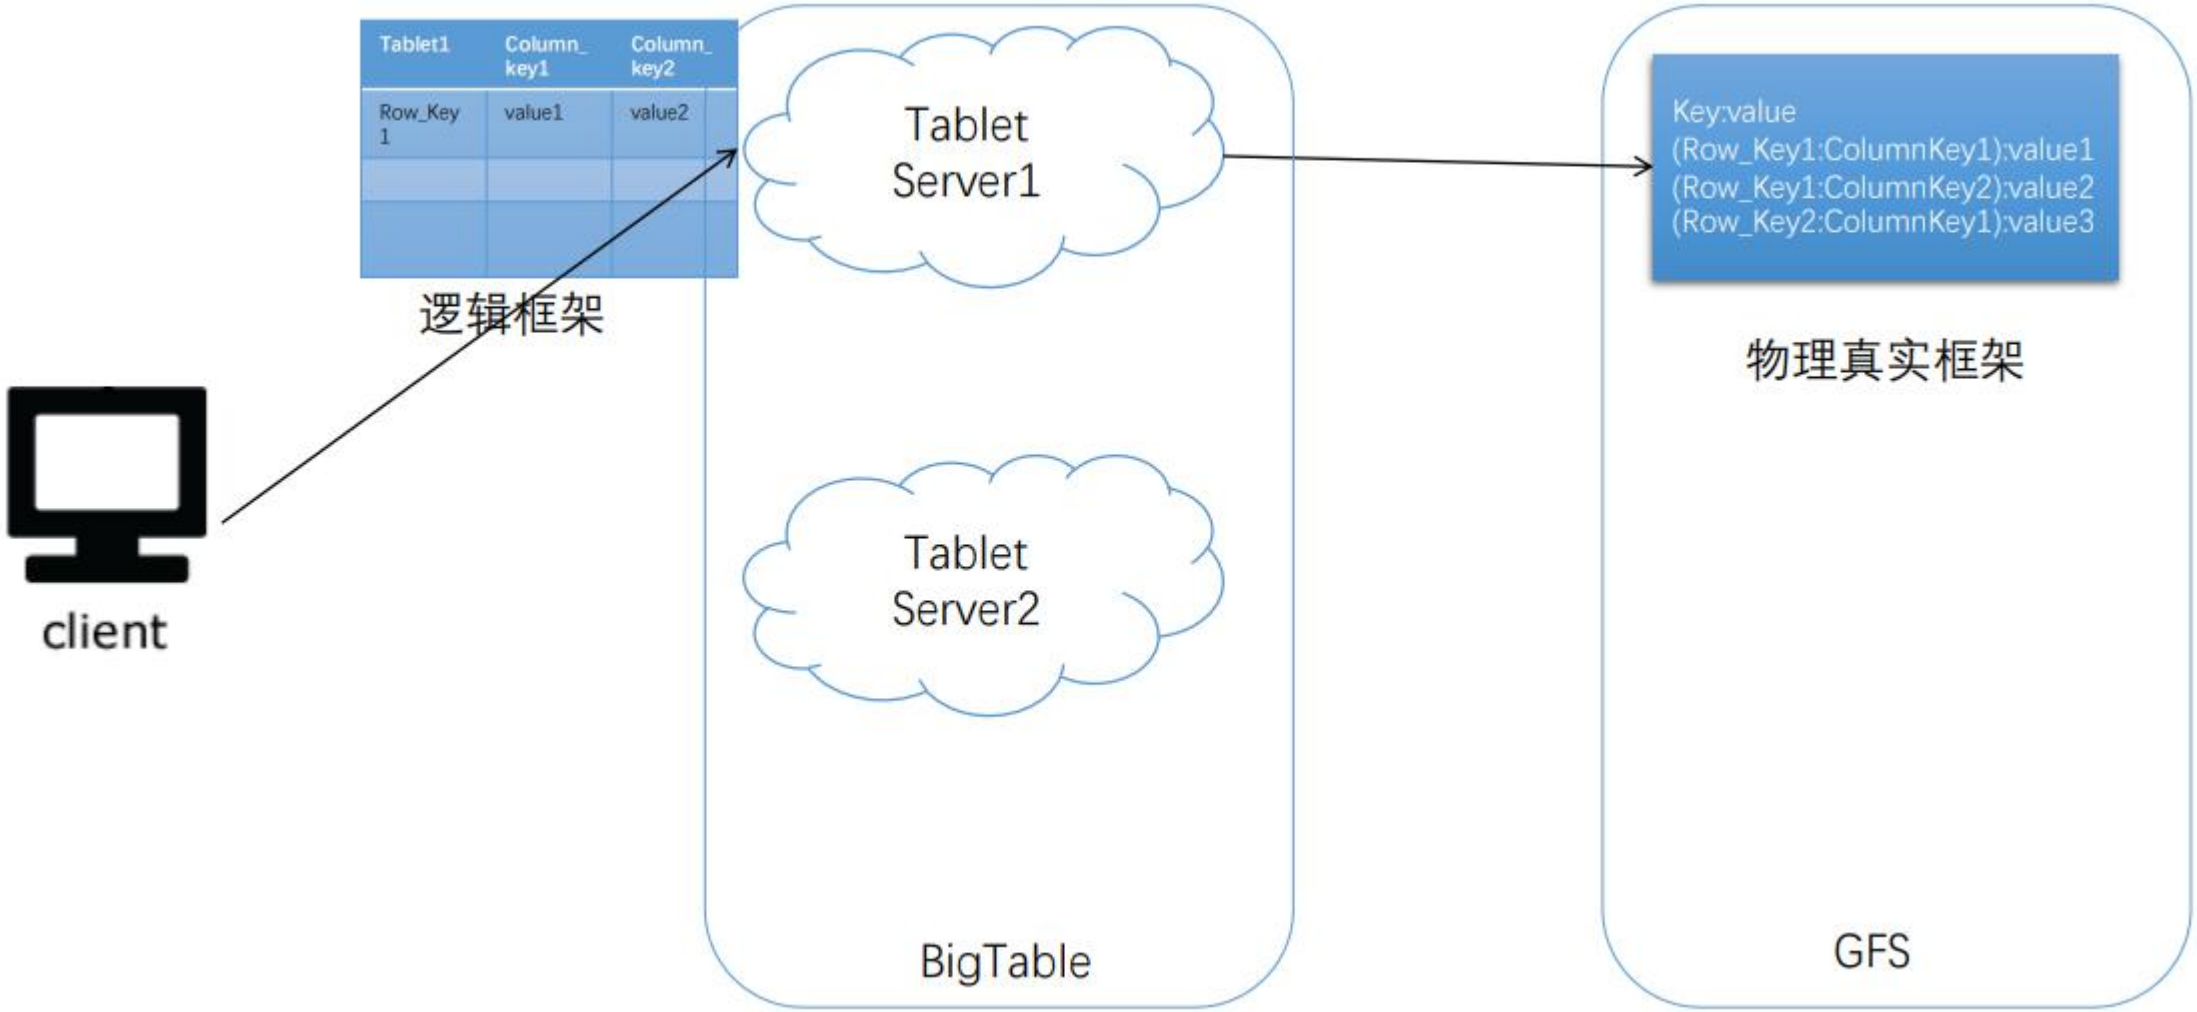

看看还有什么问题没有解决

读和写同时发生?

写的过程当中，有读请求?

Race Condition

Interviewer: What if we read and write the same key at same time?

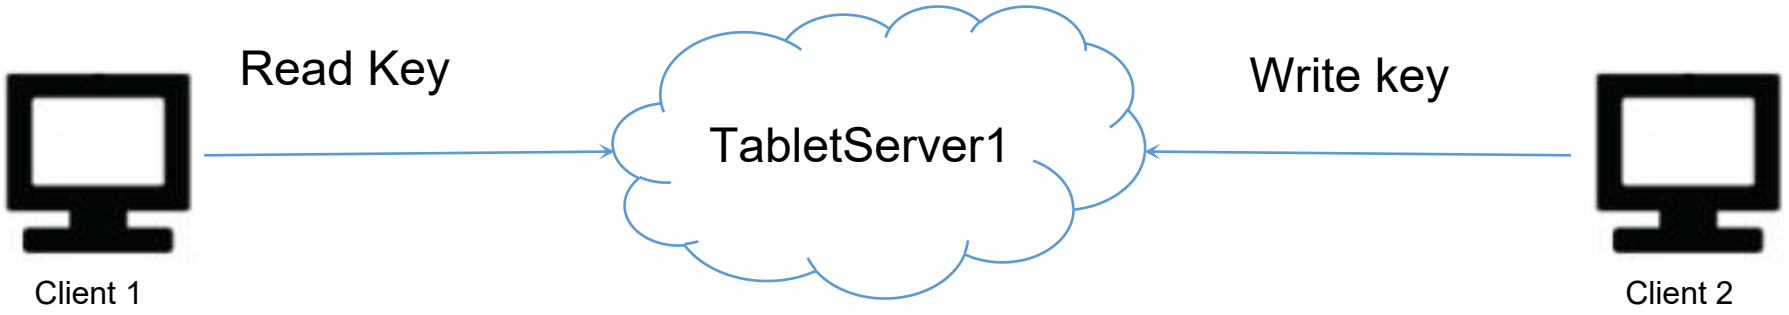

Race Condition

- http://bit.ly/25FBHM4

We need a lock

We need a distributed lock.

由多台机器组成的分布式锁服务

- Chubby
- Zookeeper

- Read More:
- http://bit.ly/1Pukiyt
- http://bit.ly/1TOWIsR

Interview: How to write a key?

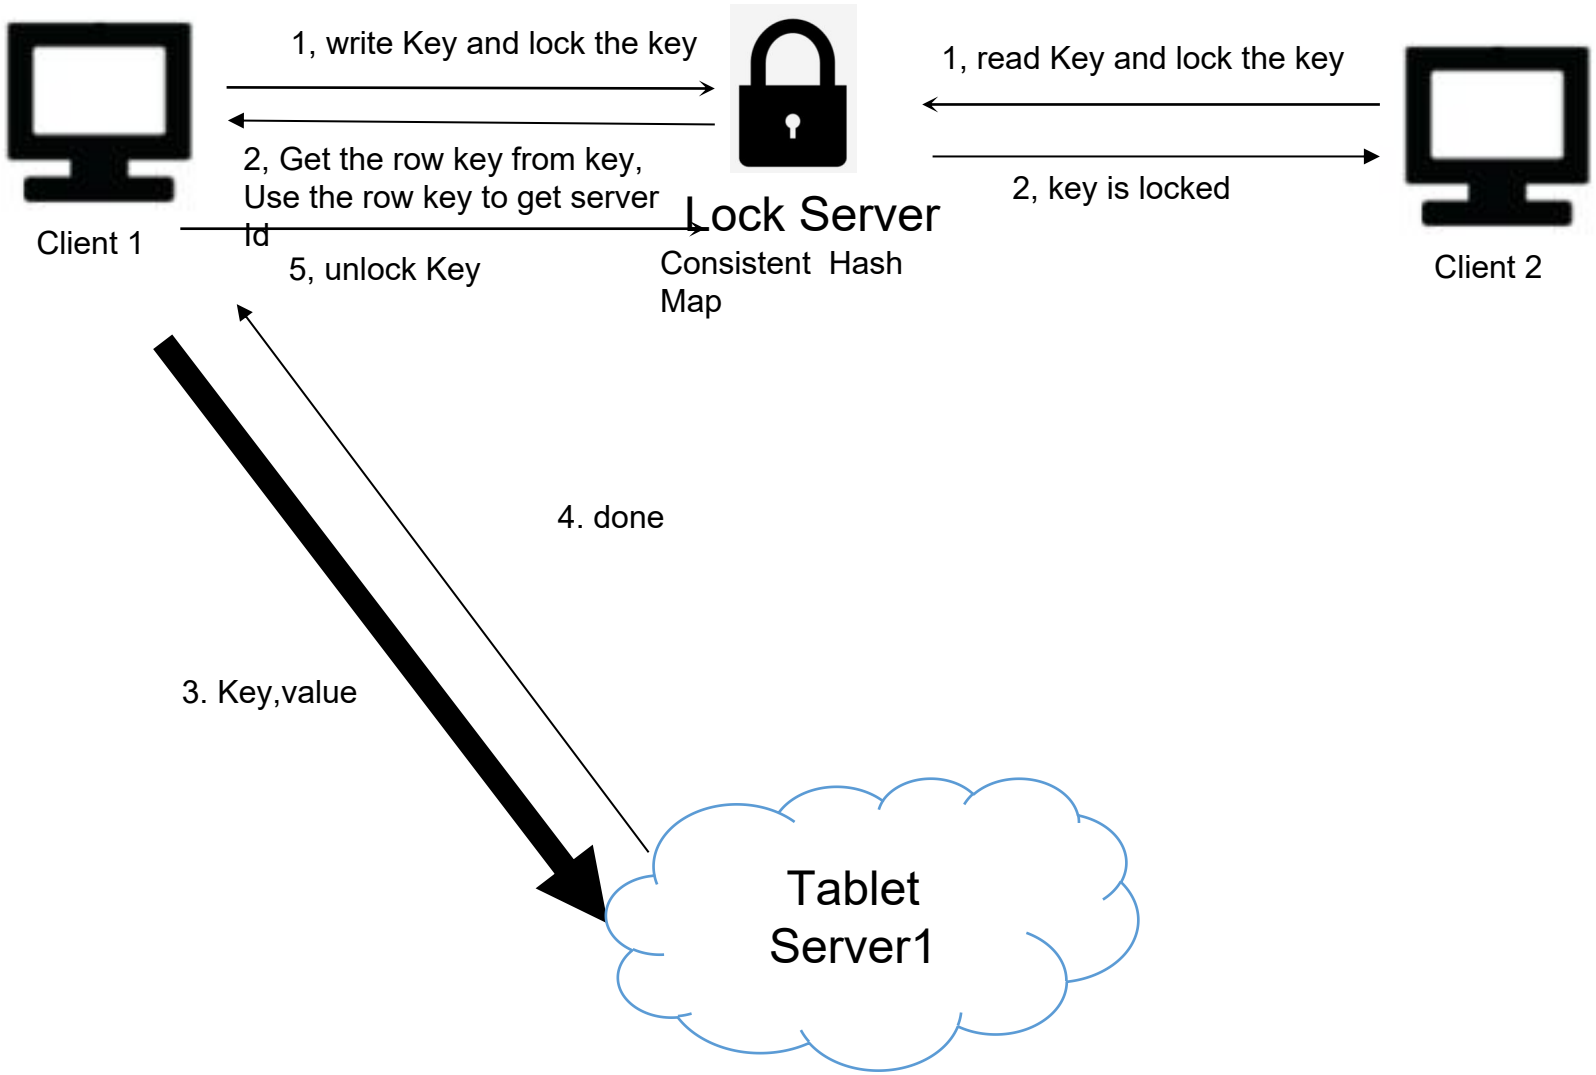

Advantage Distributed Lock

- The Metadata is store on the Lock
- Lock 本来要存储Metadata那master就不需要存储MetaData了

Summary of Write

Summary of write

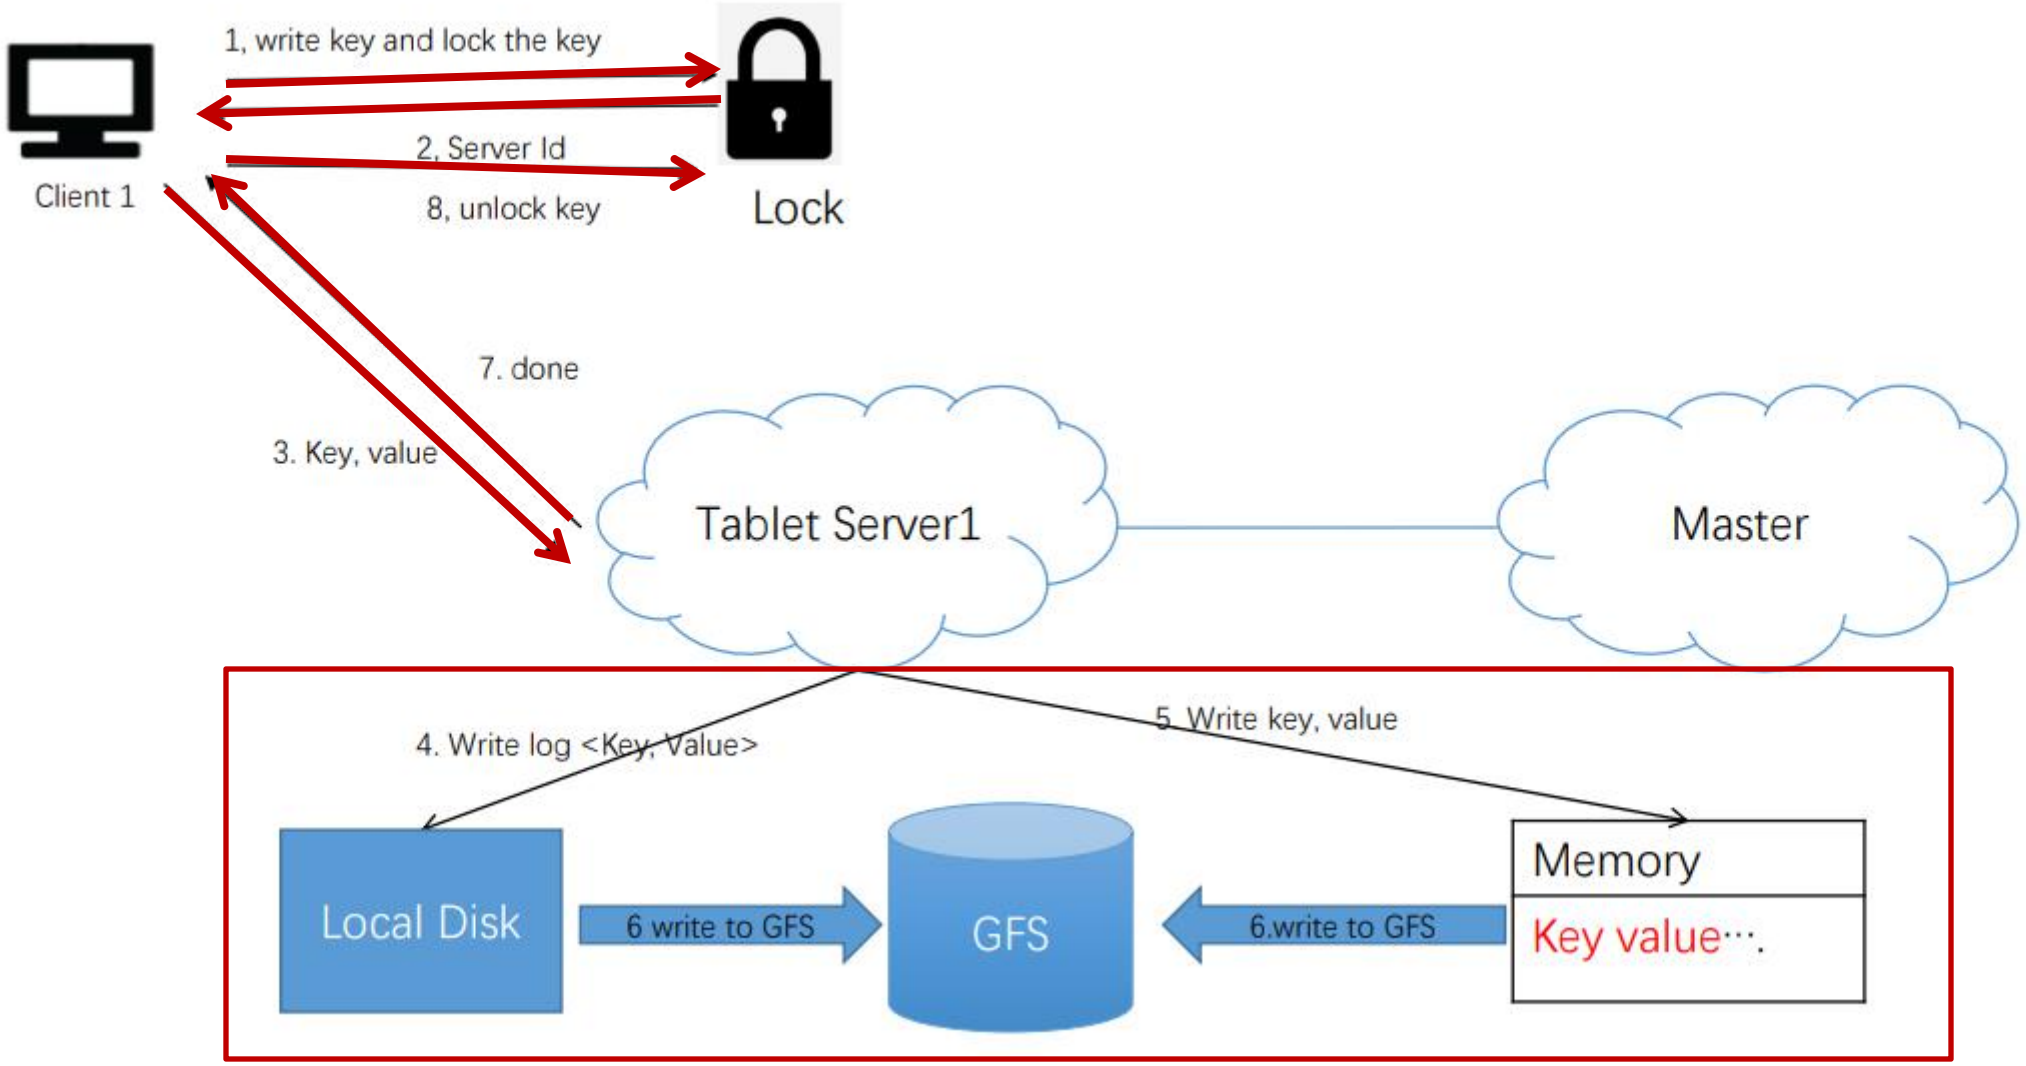

Summary of Read

Summary of Read

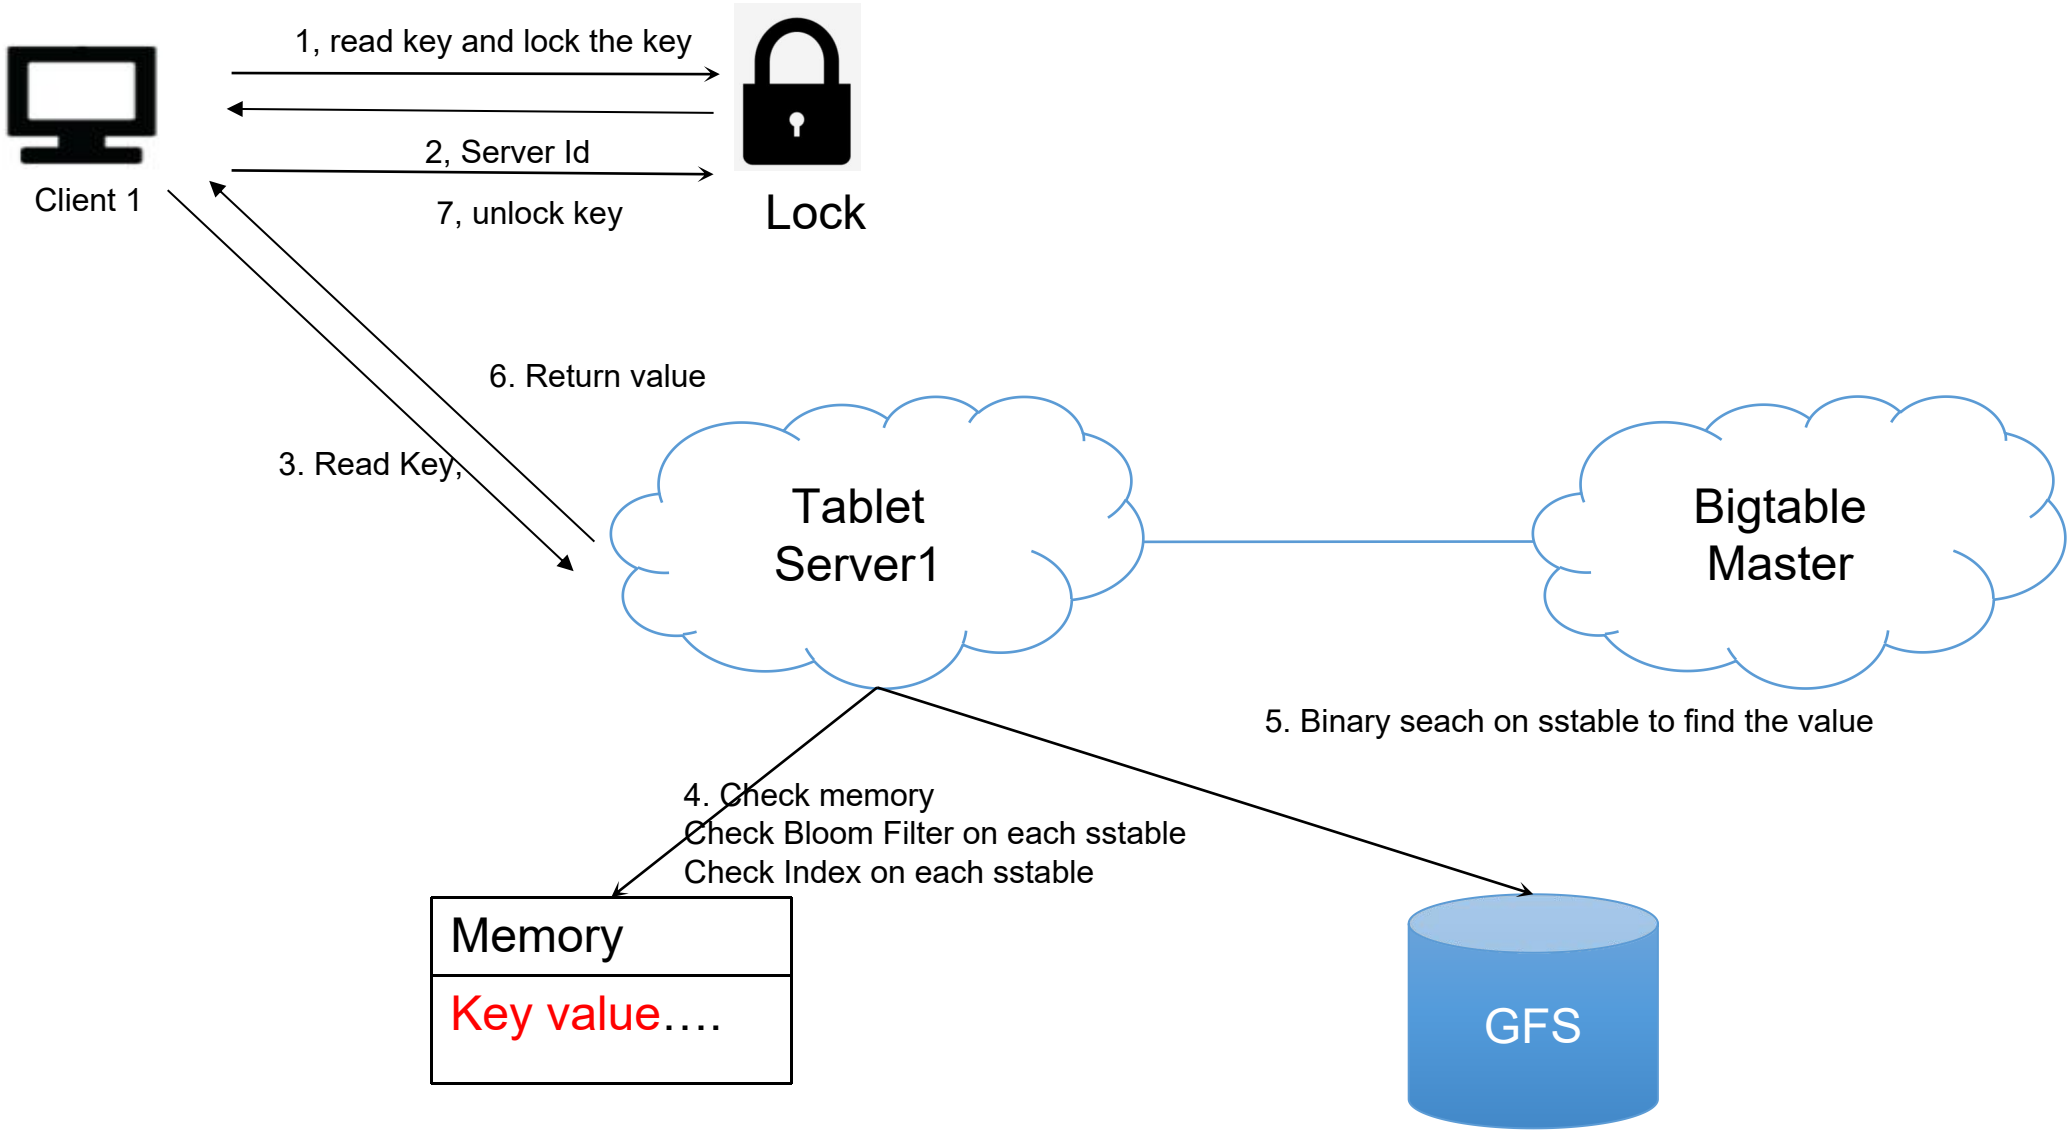

Summary of BigTable

- Design
  - Client + Master + Tablet Server + Distributed Lock
- Client
  - Read + Write
- Tablet Server
  - Maintain the Data (Key value pairs)
- Master
  - Shard the file
  - Manage the servers health
- Distributed Lock
  - Update Metadata
  - Maintain the Metadata
  - Lock Key

参考阅读

BigTable

- http://www.cse.buffalo.edu/~mpetropo/CSE736-SP10/slides/seminar100409b1.pdf

LevelDB + LSM Tree

- http://zouzls.github.io/2016/11/23/LevelDB%E4%B9%8BLSM-Tree/
- http://www.cnblogs.com/fxjwind/archive/2012/08/14/2638371.html

K 路归并 & 外排序

- 什么是K路归并？
  - 将K个已经排好序的数组，合并成一个有序数组

4路归并

2	3	7
4	6	9
1	5	11
5	8	9

1	2	3	4	5	5	6	7	8	9	9	11

- 方法

2	3	7
4	6	9
1	5	11
5	8	9

- 方法

2	3	7
4	6	9
	5	11
5	8	9

- 方法

	3	7
4	6	9
	5	11
5	8	9

- 方法

		7
4	6	9
	5	11
5	8	9

- 方法

		7
	6	9
	5	11
5	8	9

- 方法

		7
	6	9
		11
5	8	9

1	2	3	4	5	5						

- 方法

		7
	6	9
		11
	8	9

1	2	3	4	5	5	6					

K路归并

- 用什么方法找到K路中最小的元素？
  - 循环 O(K)

		7
	6	9
		11
	8	9

1	2	3	4	5	5	6					

- 用什么方法找到K路中最小的元素？
  - 循环 O(K)
  - 堆 O(logK)

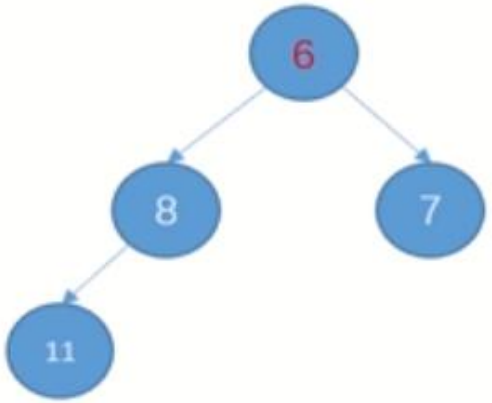

		7
	6	9
		11
	8	9

- 什么是外排序
  - 在内存只有2GB的情况下，给一个8GB大小的数组排序（数组开始放在硬盘上）
  - 要排序的数组大到内存中装不下

- 方法

- 方法

Big Table 与 GFS关系

Big Table 与 GFS关系

	GFS	Big Table
本质	分布式文件系统	分布式NoSQL Database
开发公司	Google	Google
是否开源	否	否
类似开源产品	HDFS	HBase
基本操作	读 & 写文件	增删改查记录
类似什么	家用电脑的文件系统	大数据版的Excel

Big Table 与 GFS关系

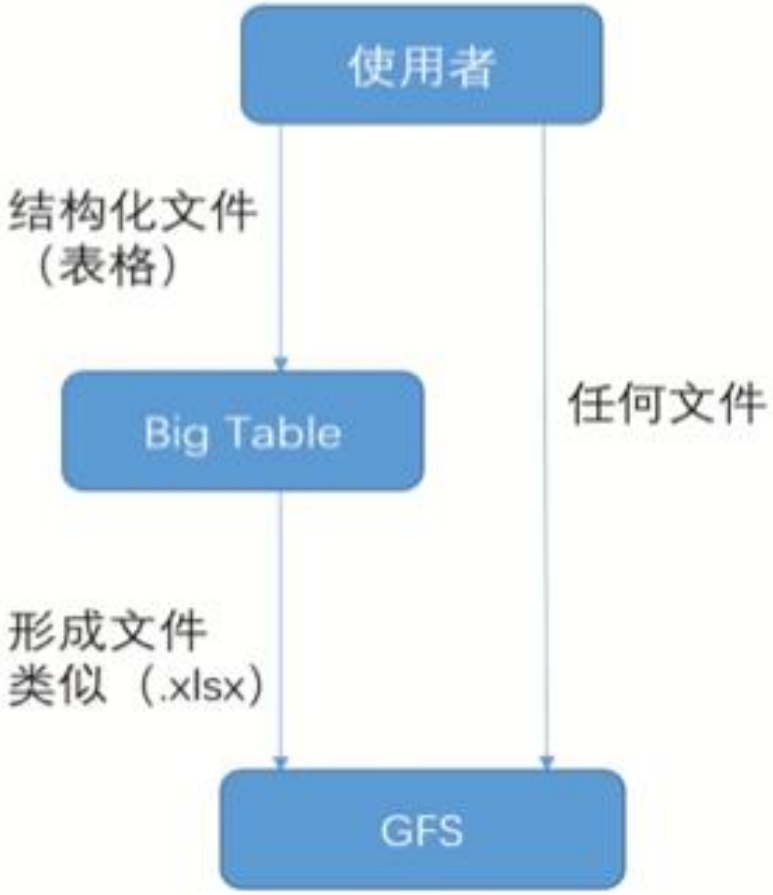

B - Tree & B + Tree

- BST
  - 左边的都比root小
  - 右边的都比root大

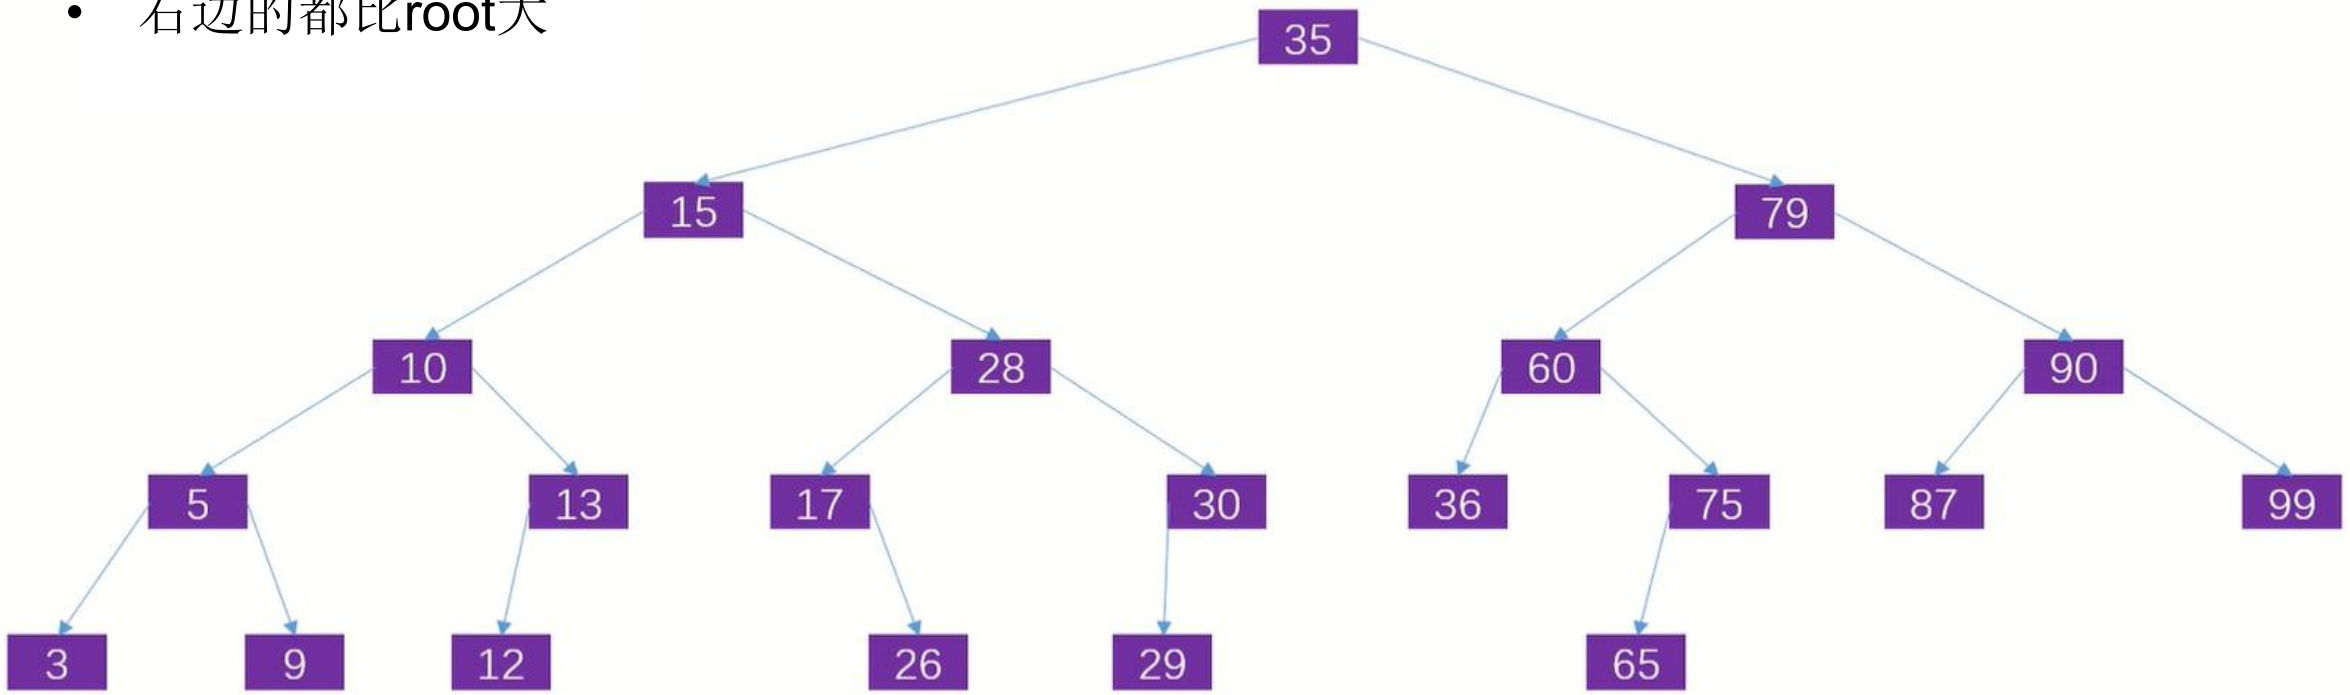

- BST
  - 查找时间与高度h有关

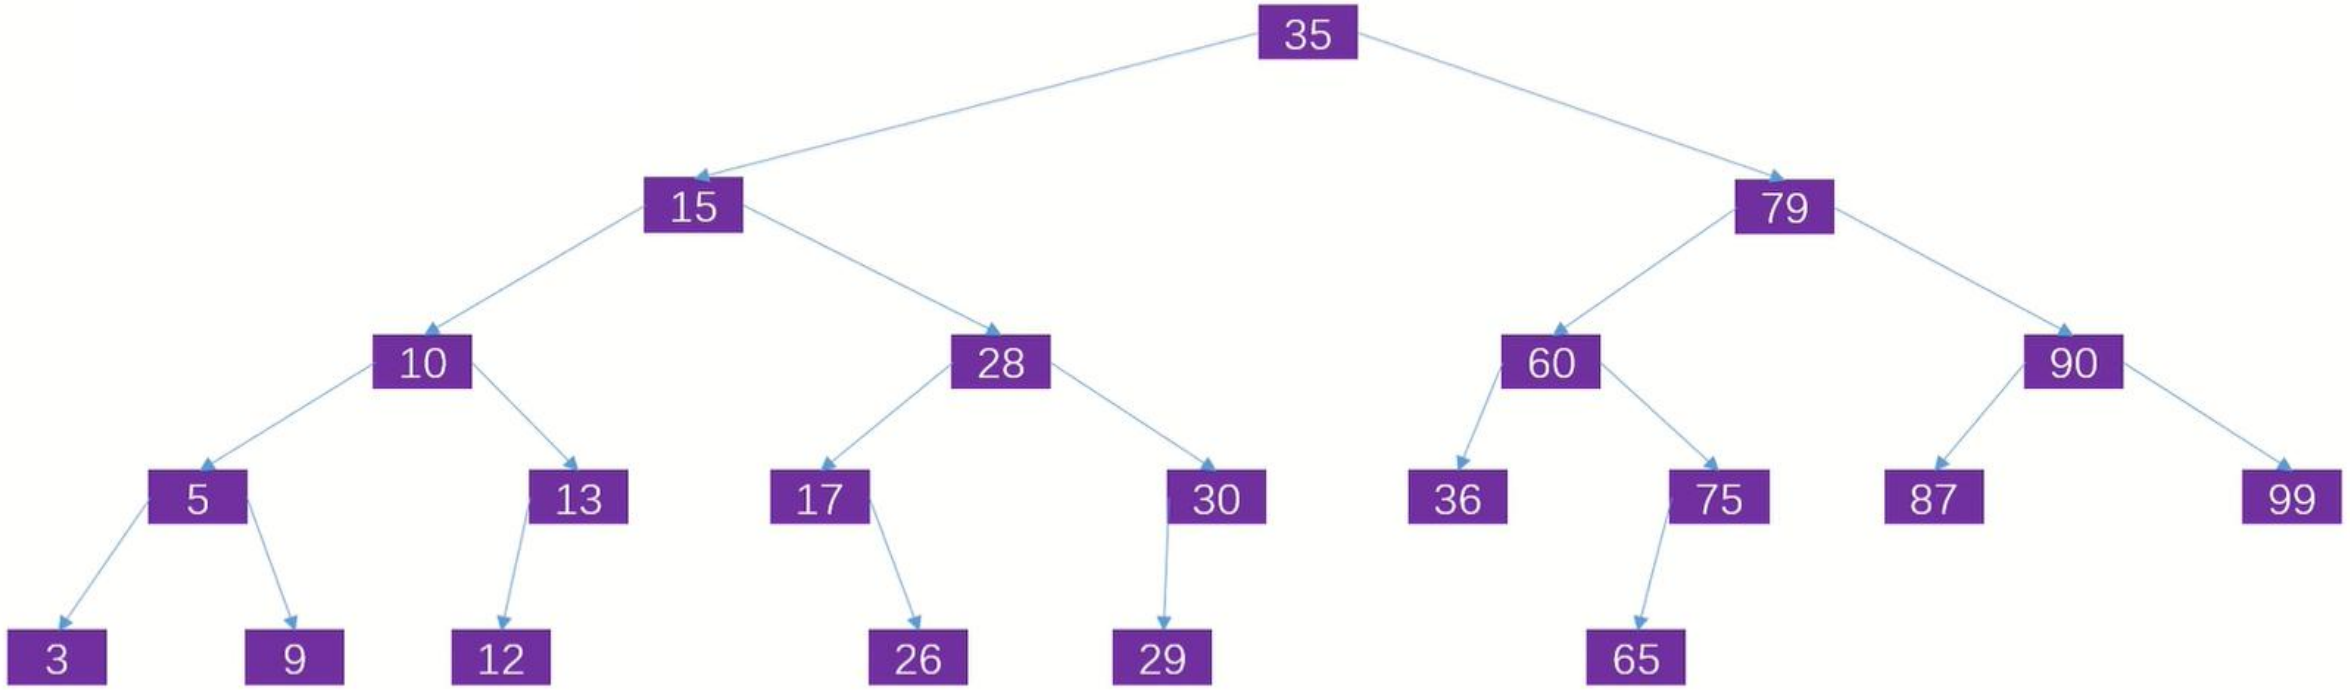

- BST
  - 如果有10亿个数据怎么办？(至少>4GB)
    - 长期保存只能存硬盘
    - 硬盘读写很慢
    - 一次寻轨10ms
    - 顺序读取80MB/s

- BST
  - 如果有10亿个数据怎么办？

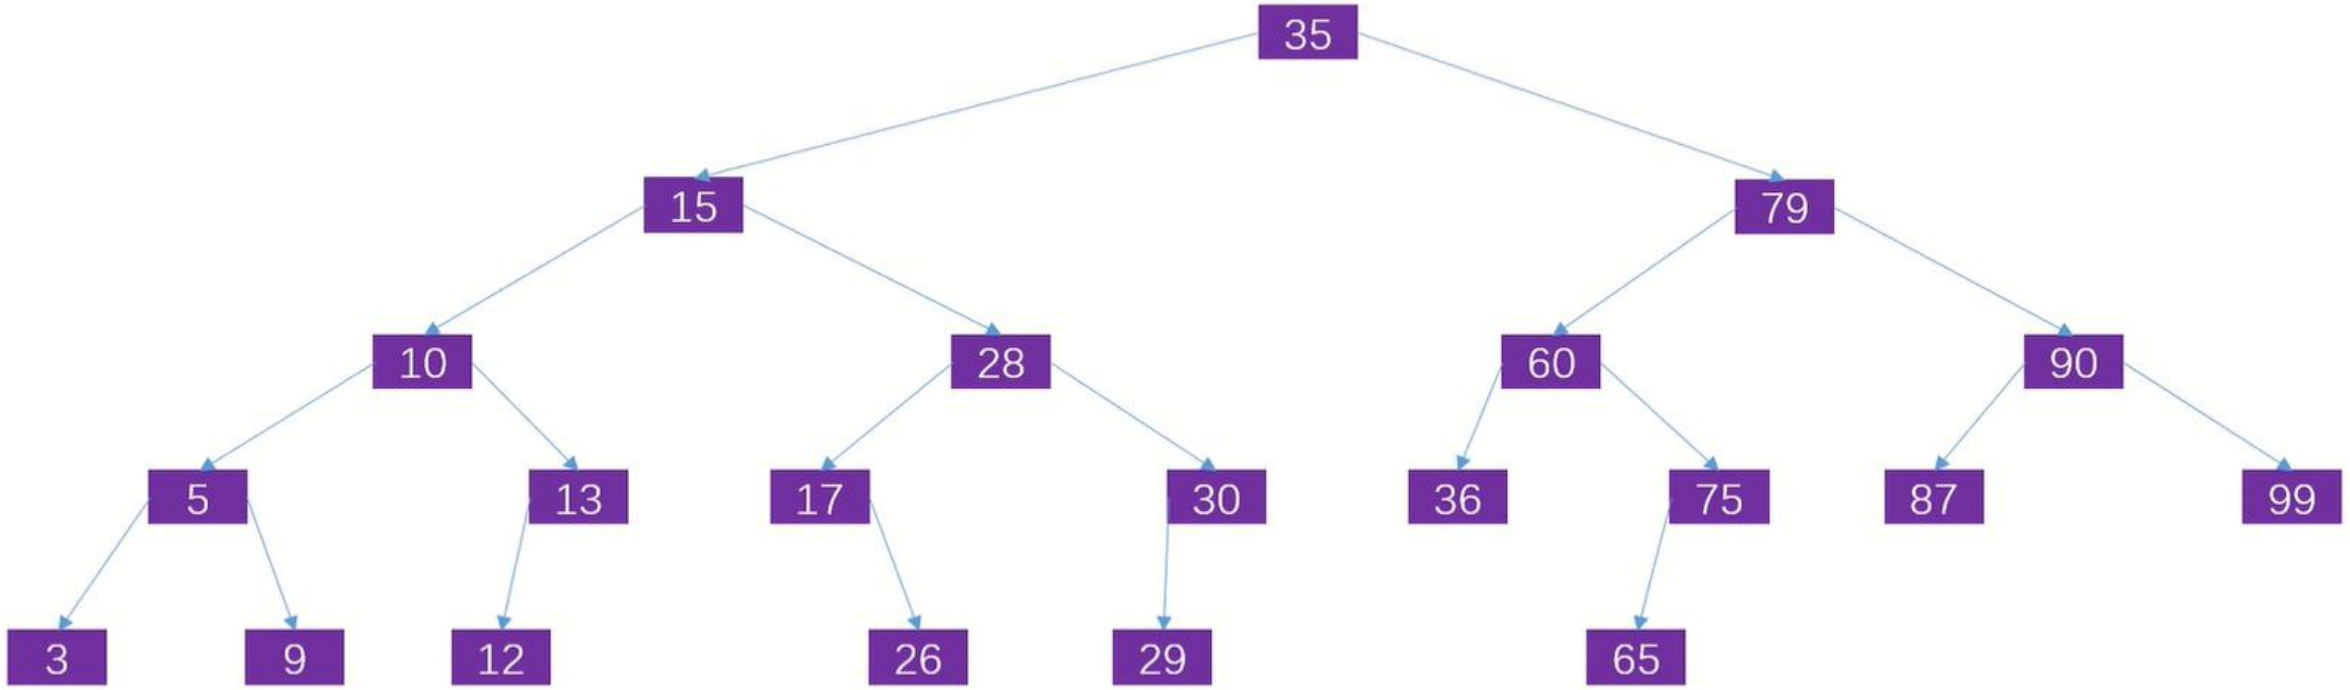

- B-Tree
  - 二叉树变成多叉树，降低树高h

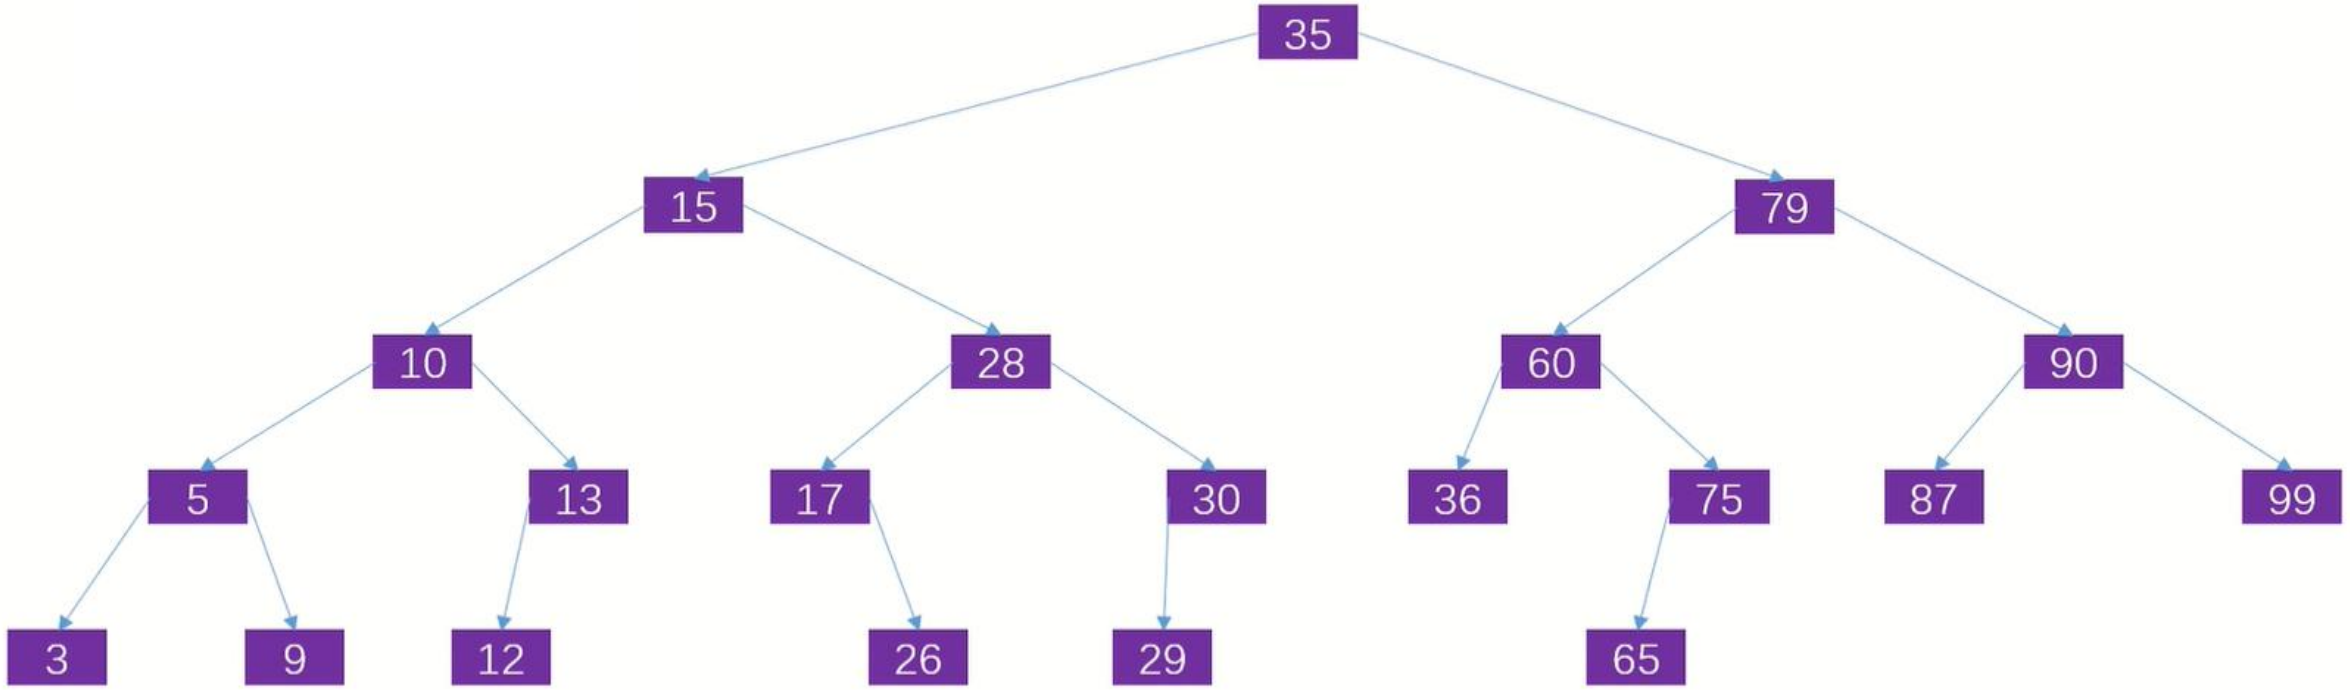

- B-Tree
  - 二叉树变成多叉树，降低树高h

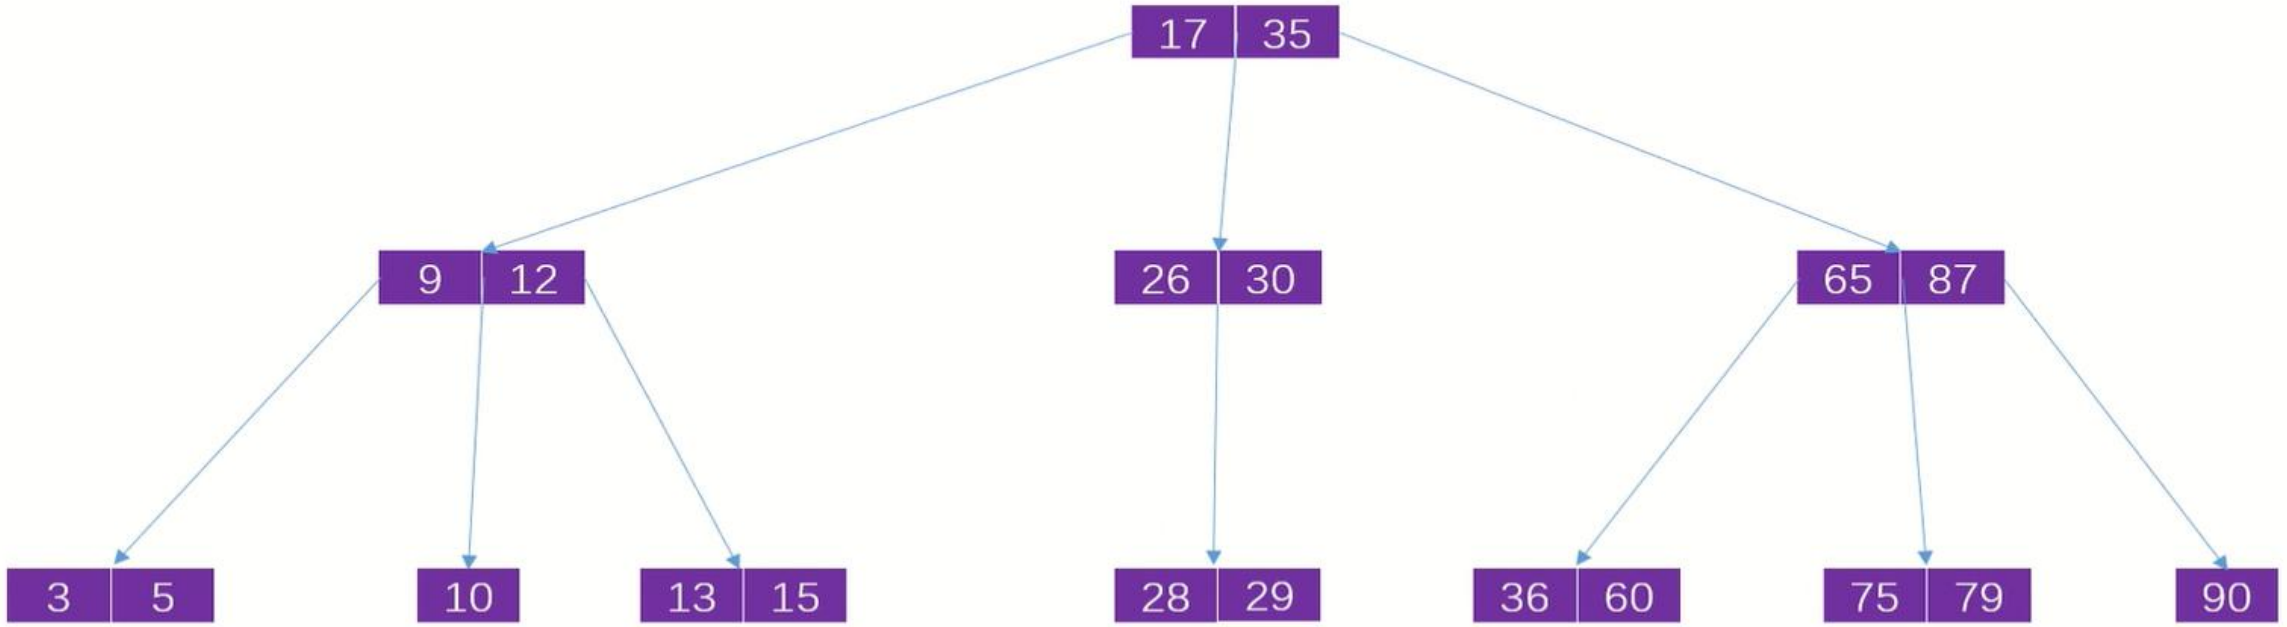

- B-Tree
  - 二叉树变成多叉树，降低树高h

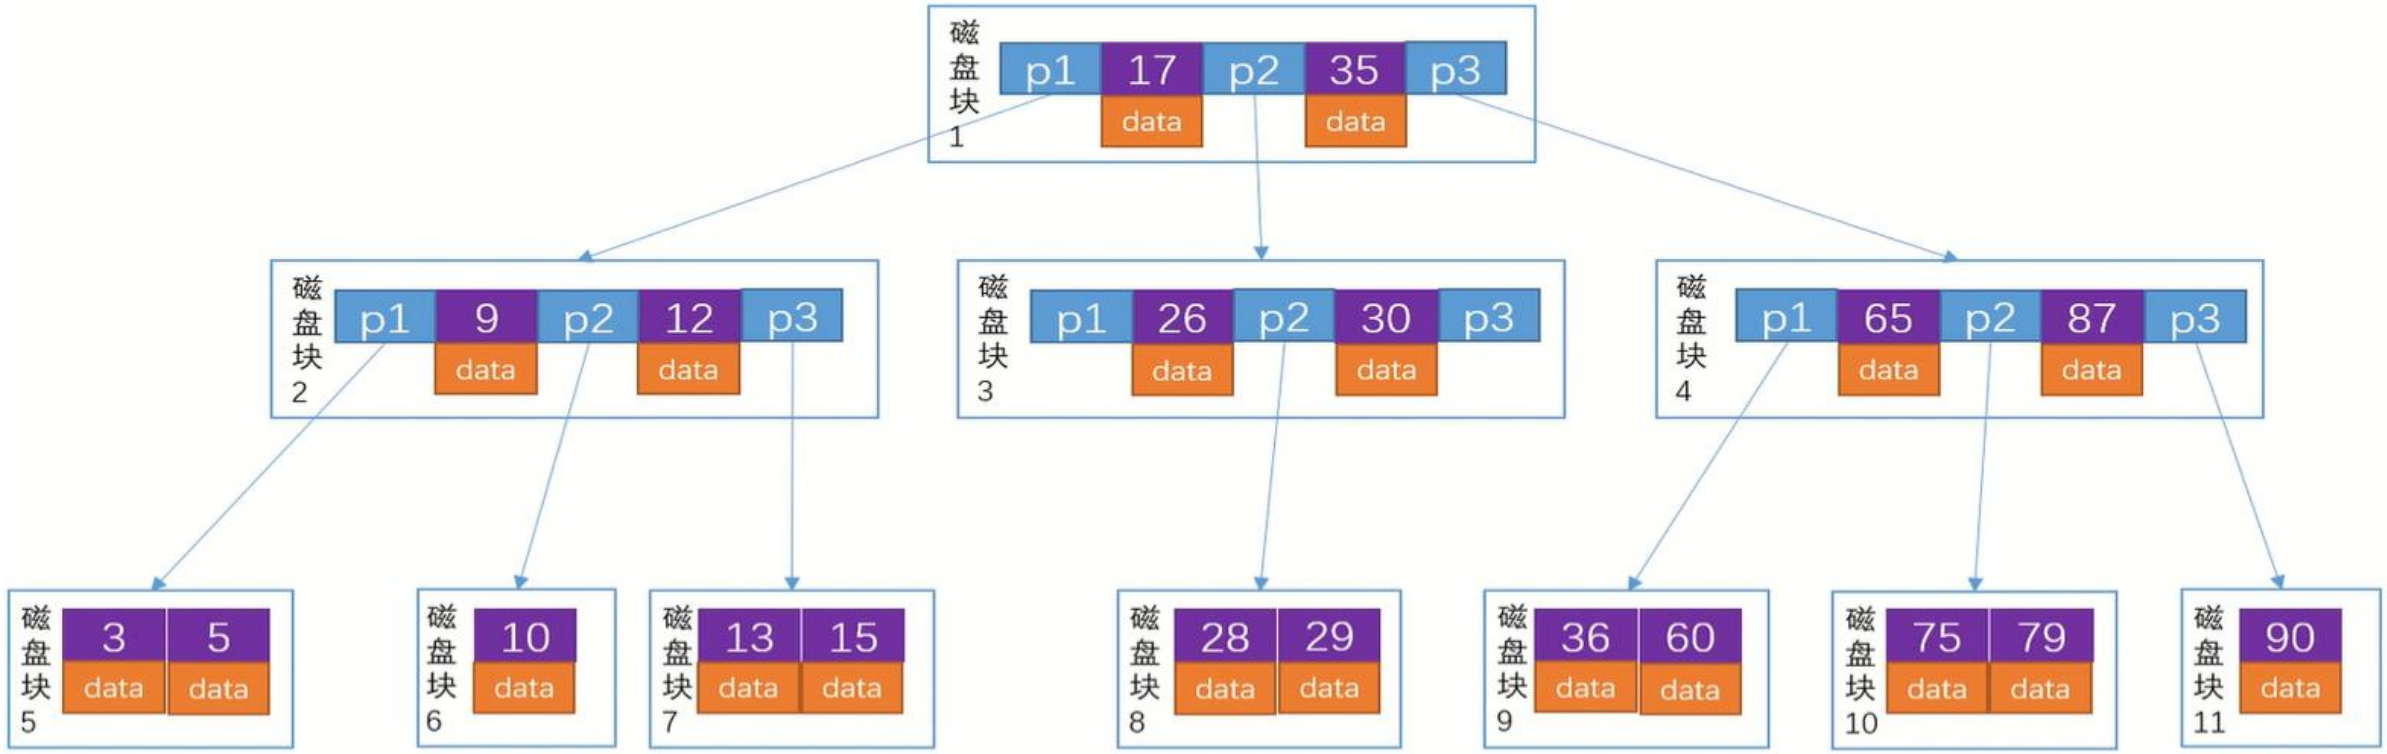

- B-Tree
  - 这样有什么问题?
    - 非叶节点data占用太多空间
    - 能存储的key的数量小(叉数小)

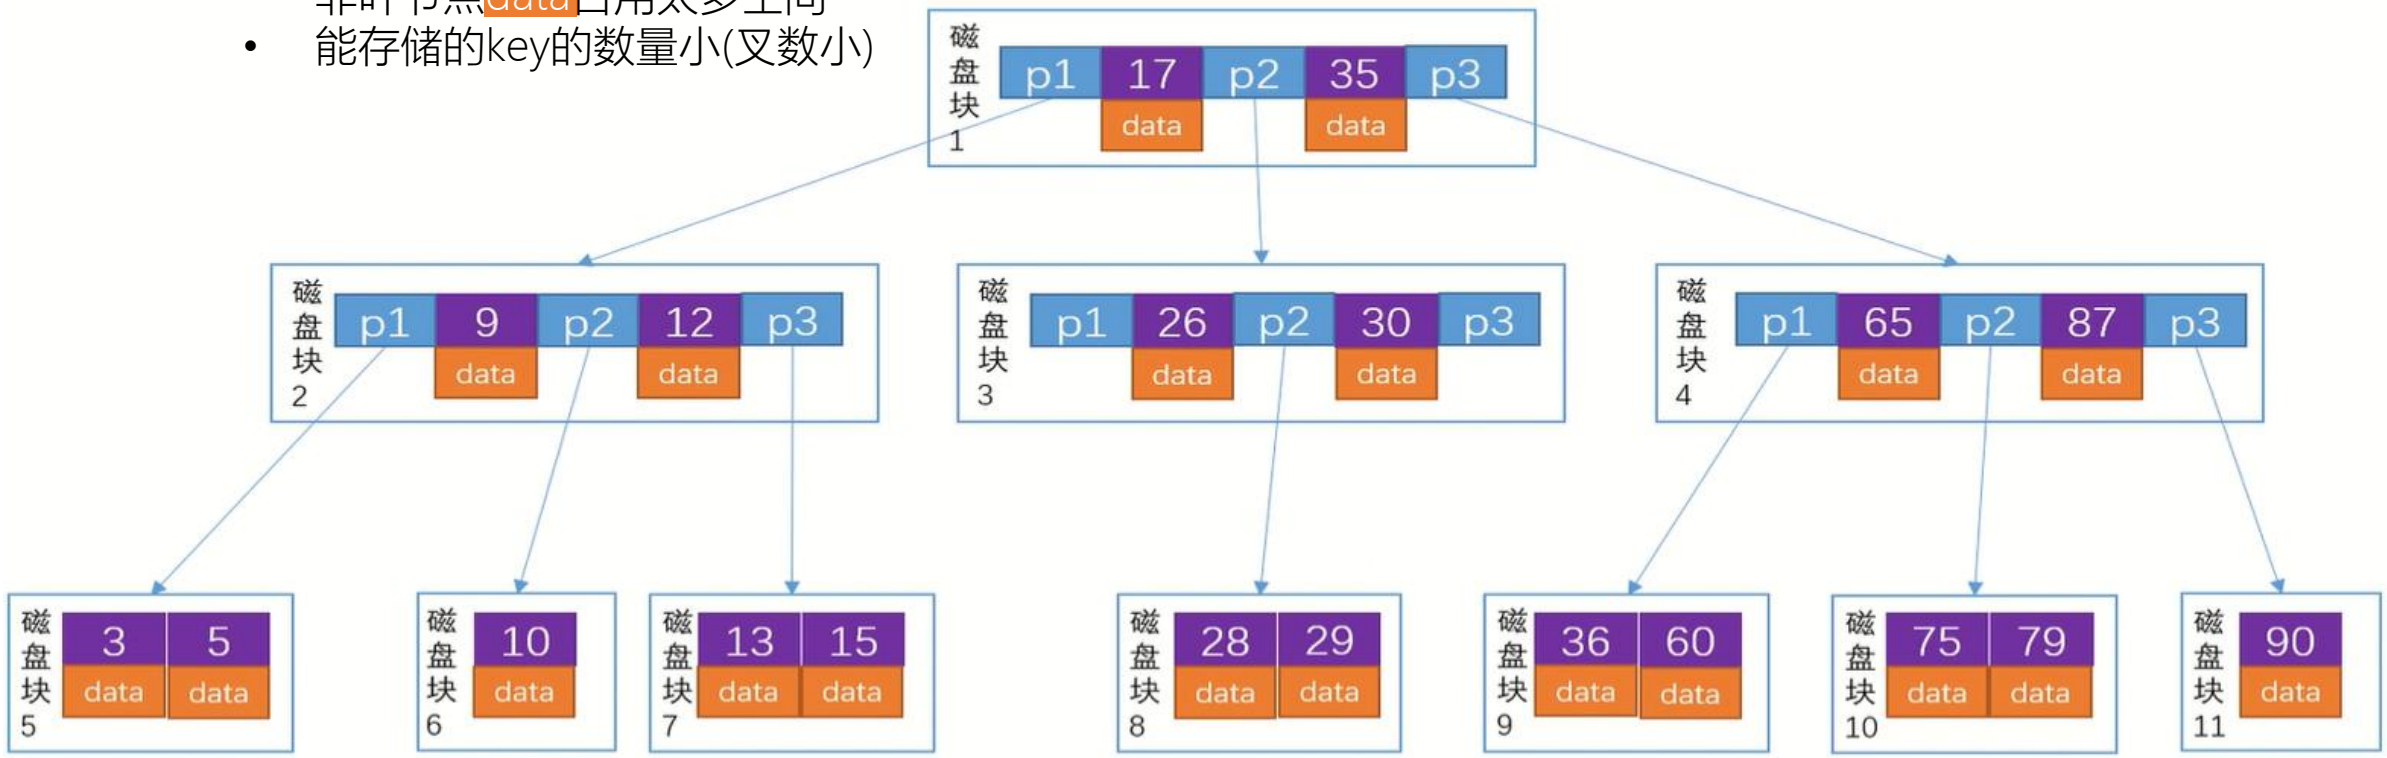

- B+Tree
  - 非叶子节点不存data

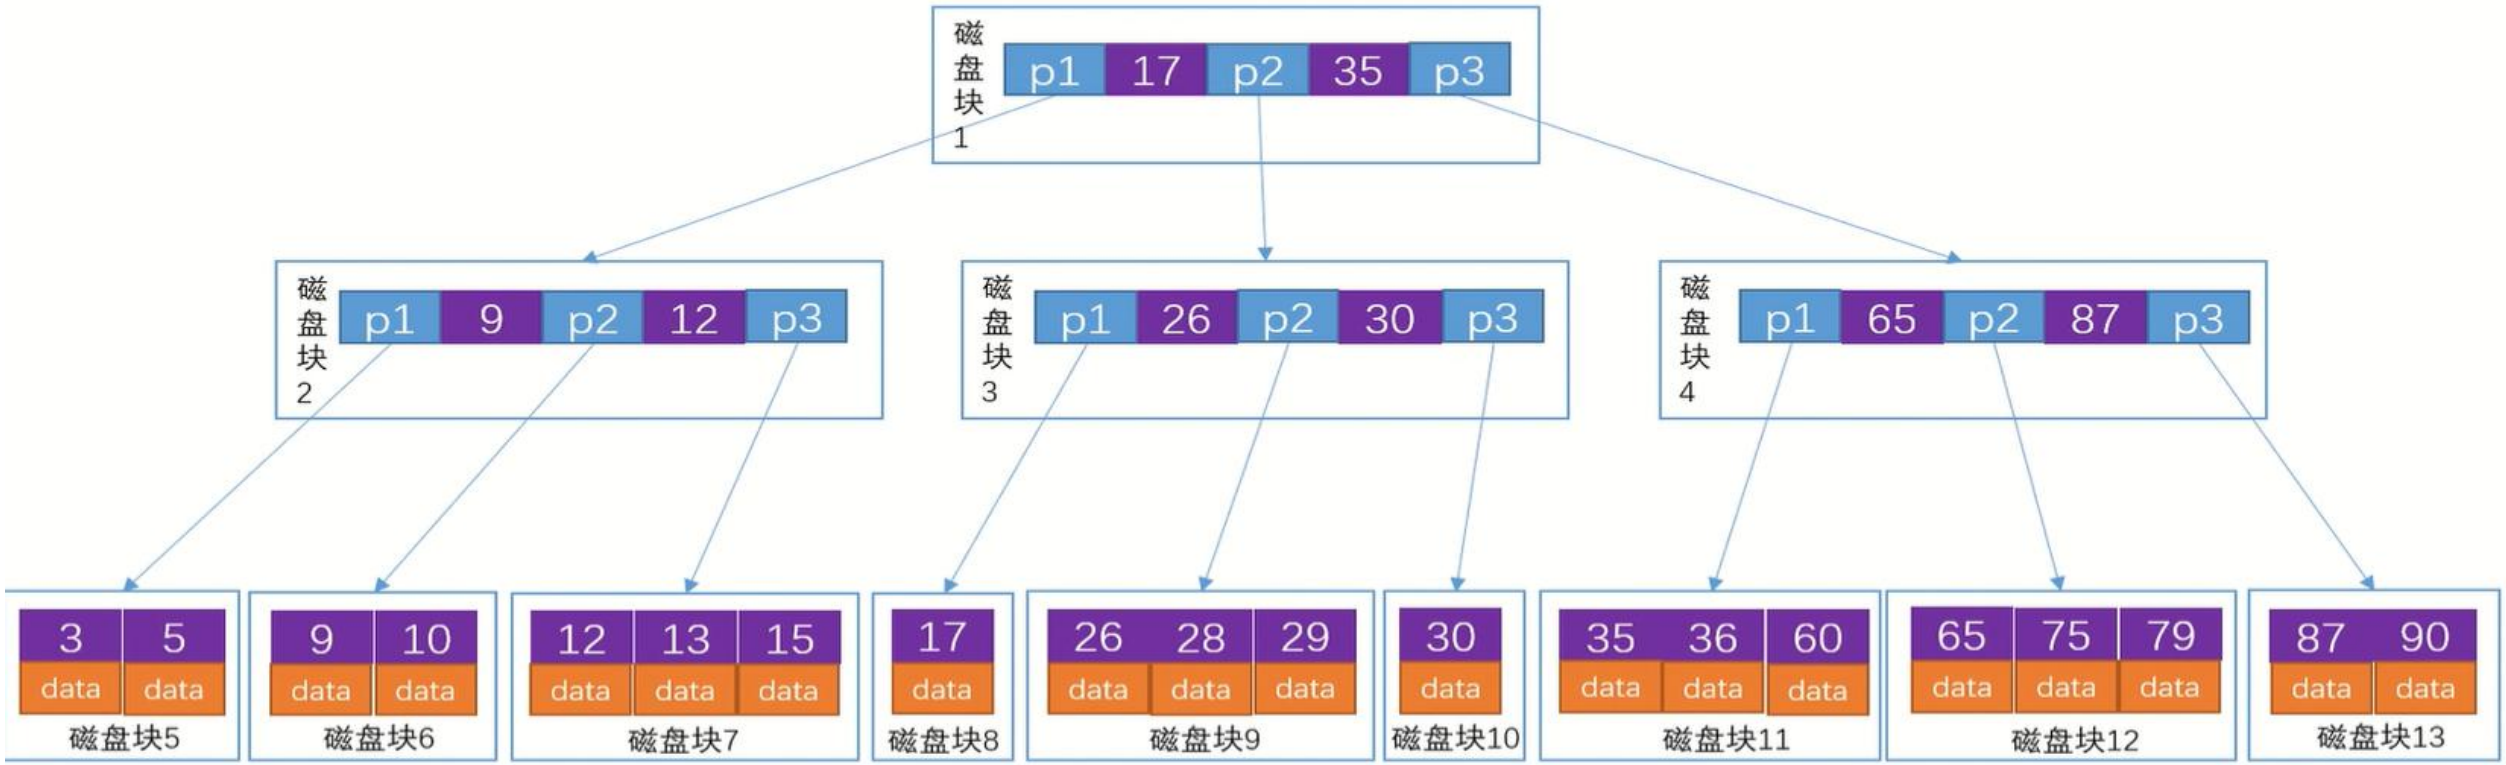

- B+Tree
  - 非叶子节点不存data

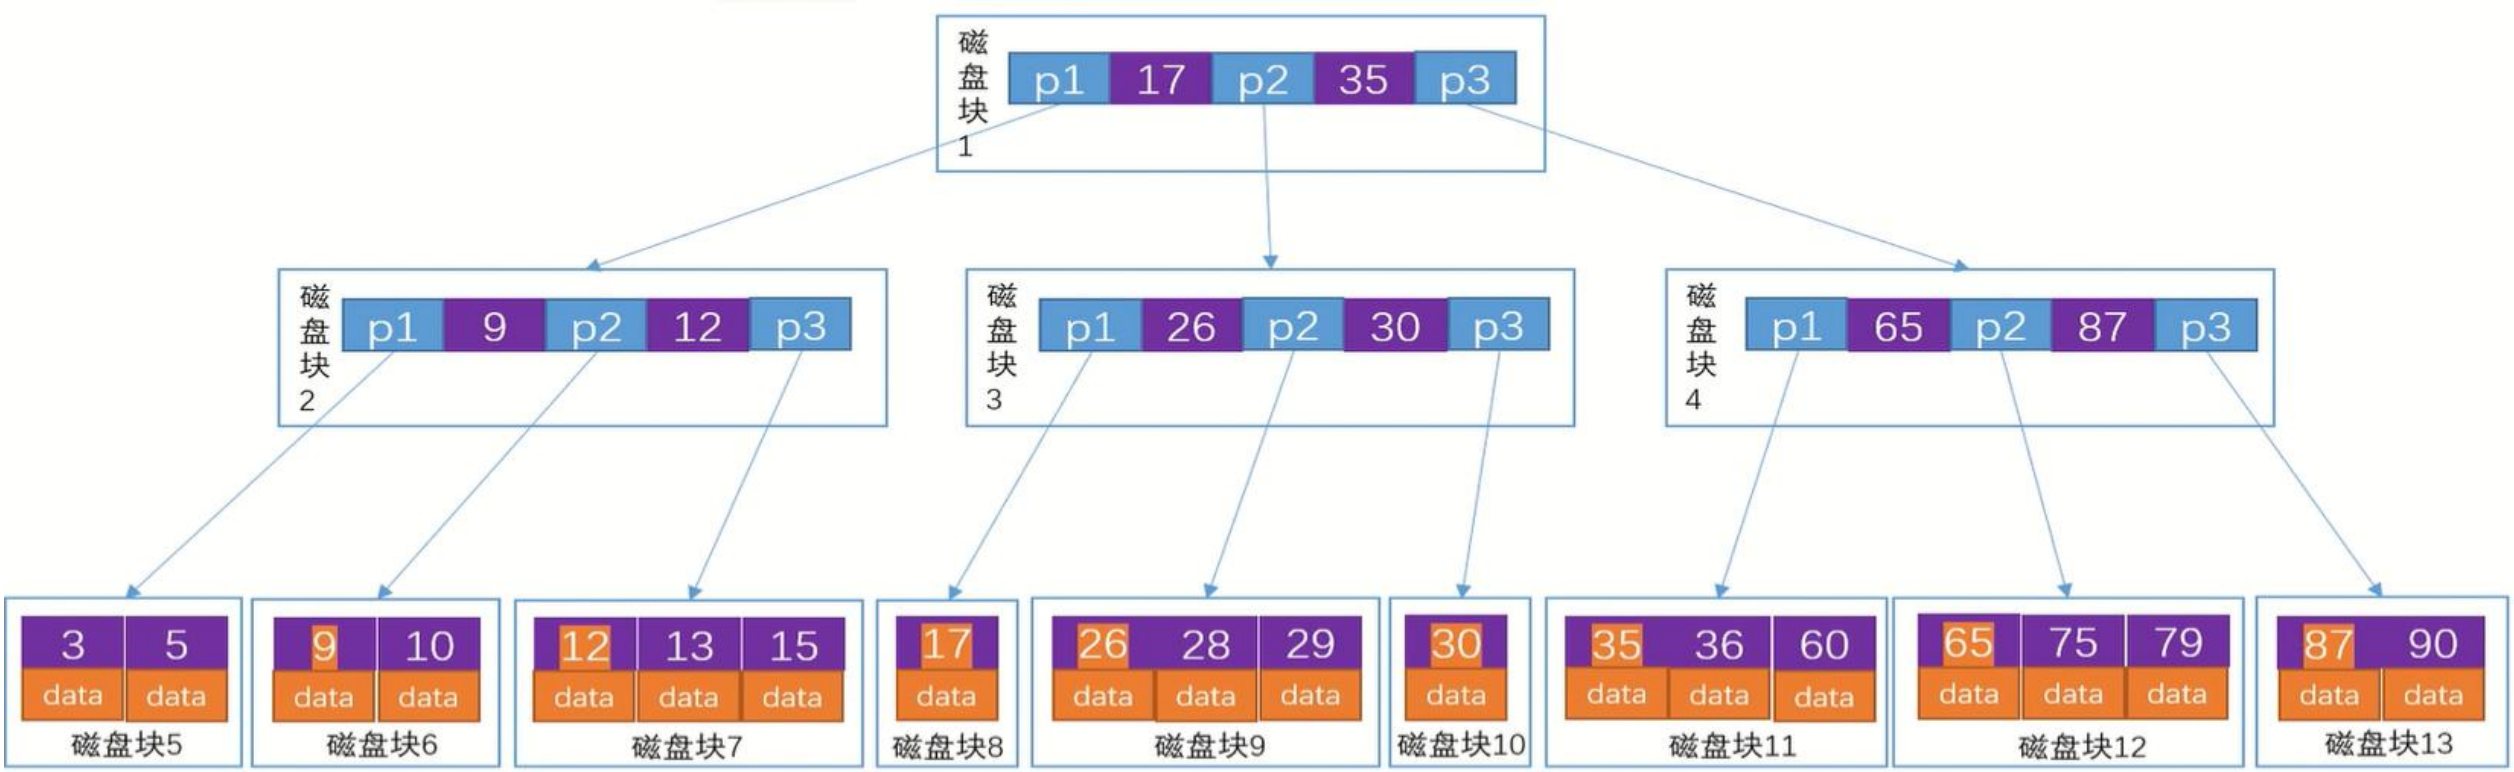

- **B+Tree**
  - 磁盘块16KB
  - 一个块大约1k个key
  - 3层10亿个key